



南开大学
Nankai University

南 开 大 学

计 算 机 学 院

深度学习实验报告

卷积神经网络

2112213 冯思程

年级：2021 级

专业：计算机科学与技术

指导教师：侯淇彬

2025 年 5 月 29 日

摘要

本文介绍并实现了多种卷积神经网络结构，并在 CIFAR-10 数据集上进行了训练与测试，主要包括原始卷积网络、ResNet-18、DenseNet 和 SE-ResNet-18。实验结果表明，改进后的三种网络在分类性能上明显优于原始网络。本文还探索了 Res2Net 架构的表现，并进行了相关对比分析。未来工作可进一步测试其他网络结构，评估其在不同任务和数据集上的性能表现。

关键字：CNN, CIFAR10, ResNet, DenseNet, SE-ResNet, Res2Net

目录

一、 研究背景与准备	1
(一) 研究背景	1
(二) 数据集	1
(三) 实验设置	1
二、 基础 CNN	1
(一) 网络结构	1
(二) 实验结果	2
三、 ResNet	2
(一) 网络结构	2
(二) 实验结果	3
四、 DenseNet	3
(一) 网络结构	3
(二) 实验结果	4
五、 SE-ResNet	4
(一) 网络结构	4
(二) 实验结果	5
六、 网络结构对比分析	5
七、 扩展: Res2Net	7
(一) 网络结构	7
(二) 实验结果	7
八、 实验心得	8

一、研究背景与准备

(一) 研究背景

卷积神经网络 (Convolutional Neural Networks, CNNs) 近年来在计算机视觉领域取得了显著进展,尤其在图像分类任务中表现出卓越的性能。早期的研究 [1,7] 在大规模图像分类任务中展示了深度神经网络的潜力。随后, VGG 网络 [8] 通过堆叠更多层的卷积网络进一步提升了分类精度。在此基础上,越来越多的改进结构被提出以解决深层网络中的梯度消失、特征复用不足等问题。其中, ResNet [3] 通过引入残差连接,有效缓解了深度网络训练困难的问题。而 DenseNet [5] 则通过在网络中引入密集连接,极大增强了特征传递和复用能力。此外,为进一步提升模型的表示能力, SE 模块 (Squeeze-and-Excitation Networks) [4] 被提出,并集成到 ResNet 等主干网络中,以显式建模通道间的依赖关系。本文进一步探索了 Res2Net 网络 [2],该方法通过多尺度特征分支增强了模型在图像分类任务中的多尺度表达能力,为提升分类性能提供了新的方向。

本研究以图像分类为任务主线,系统评估了 ResNet、DenseNet、SE-ResNet 和 Res2Net 等不同网络架构在标准数据集上的表现,旨在探讨不同结构改进对分类精度与效率的影响。

(二) 数据集

本研究采用的实验数据集为 CIFAR-10 [6],这是一个广泛用于图像分类的标准基准数据集。CIFAR-10 数据集包含 60,000 张 32×32 像素的彩色图像,共分为 10 个类别。其中,训练集包含 50,000 张图像,测试集包含 10,000 张图像。所有类别均衡,每类图像数量相同。本文基于该数据集进行训练和测试,以分析不同网络结构在图像分类任务中的准确率与损失等指标。

(三) 实验设置

实验中设置 batch size 为 32,最大训练轮数为 20 (这里我已确保了后文的实验都训练到收敛状态)。我额外引入了早停机制 (Early Stopping),当验证集准确率连续 3 次未提升时提前终止训练,以避免过拟合。所有实验在一张 RTX 4090 GPU 上完成。

二、基础 CNN

(一) 网络结构

基础的 CNN 架构较为简洁,由两个卷积层和三个全连接层组成,用于处理图像分类任务。具体网络结构如下:

```
Net(  
    (conv1): Conv2d(3, 6, kernel_size=(5, 5), stride=(1, 1))  
    (pool1): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)  
    (conv2): Conv2d(6, 16, kernel_size=(5, 5), stride=(1, 1))  
    (fc1): Linear(in_features=400, out_features=120, bias=True)  
    (fc2): Linear(in_features=120, out_features=84, bias=True)  
    (fc3): Linear(in_features=84, out_features=10, bias=True)  
)
```

(1)输入图像大小为 $[3, 32, 32]$ 。首先通过卷积层 $\text{Conv2d}(3, 6, 5)$,输出特征图尺寸为 $[6, 28, 28]$ 。经过 ReLU 激活和 2×2 最大池化后,特征图降采样为 $[6, 14, 14]$ 。




图 1: 基础 CNN 网络在验证集上的损失与准确率

(2) 随后通过第二个卷积层 Conv2d(6, 16, 5), 输出尺寸为 $[16, 10, 10]$ 。再经过一次最大池化后, 特征图变为 $[16, 5, 5]$ 。

(3) 最后将输出展平成长度为 $16 \times 5 \times 5 = 400$ 的向量, 依次输入三个全连接层进行特征提取与分类, 维度变化为 $400 \rightarrow 120 \rightarrow 84 \rightarrow 10$, 输出为 10 个类别的预测结果。

(二) 实验结果

由于该网络结构较为简单, 模型的表达能力有限, 因此即使对学习率和动量进行多轮调参, 整体性能提升仍较为有限。最终, 在学习率设置为 0.01、动量设置为 0.9 的配置下, 验证集上取得了最高 65.09% 的准确率。如图 1 所示, 模型在第 17 个 epoch 达到收敛并触发早停机制, 整体训练过程稳定。

三、 ResNet

(一) 网络结构




图 2: ResNet18 的架构图

ResNet 网络通过引入残差连接, 有效缓解了深层网络中梯度消失的问题, 使得神经网络可以更稳定地加深。在每个残差单元中, 输入绕过两个卷积层直接相加, 实现跨层信息传递。在本




图 3: ResNet18 在验证集上的损失与准确率

实验中，考虑到 CIFAR-10 是一个相对简单的分类任务，我们选用了较浅的 ResNet18 结构进行实现。

该网络以一个 3×3 卷积层作为起始，用于将输入图像的通道扩展到 64。随后依次堆叠 4 个残差模块，每个模块包含 2 个残差单元，通道数依次为 64、128、256 和 512，每个模块的首个单元通过步长为 2 的卷积进行下采样。在所有残差模块之后，网络通过全局平均池化将特征图压缩为通道向量，最终通过全连接层输出 10 类预测结果。结构如图 2 所示。

(二) 实验结果

如图 3 所示，展示了在学习率设为 0.01、动量为 0.9 的配置下，ResNet18 在验证集上的表现。模型在第 17 个 epoch 触发早停，最终准确率稳定在约 84%，显著优于基础 CNN，并成功收敛，其中最佳准确率是 84.31%。值得注意的是，在训练后期，尽管验证准确率仍在缓慢提升，验证损失却出现上升。这说明模型的预测变得更为“极端”，即对大多数样本置信度更高，但对个别错误样本的容错率降低，导致损失增加。这可能暗示模型开始出现轻度过拟合的趋势。

四、 DenseNet

(一) 网络结构




图 4: DenseNet 的架构图

DenseNet 通过在网络中建立前后层之间的密集连接，有效提升了特征复用能力与梯度传递效率。与 ResNet 仅进行相邻层残差连接不同，DenseNet 中的每一层都会接收前面所有层的输出作为其输入，并将自己的输出传递给后续所有层，从而在通道维度上实现了特征级联。这种设计不仅缓解了梯度消失问题，还显著减少了参数数量与计算开销。

在本实验中，所实现的 DenseNet 结构由 3 个 DenseBlock 构成，每个 DenseBlock 包含 3 个 Bottleneck 单元。每个 Bottleneck 由一个 1×1 卷积和一个 3×3 卷积组成，前者用于压缩维




图 5: DenseNet 在验证集上的损失与准确率

度（输出为 $4k$ 个通道），后者用于提取特征（输出为 k 个通道）。在 block 内部，所有 bottleneck 的输入由其前面所有层的输出在通道维度上拼接而成，实现真正的“密集连接”。

在 DenseBlock 之间使用 Transition 层进行特征图尺寸和通道数的压缩，我在实现中将通道数缩减为原来的一半。最终，通过全局平均池化与全连接层完成分类任务。本实验设置的增长率 (growth rate) 为 $k = 12$ ，结构如图 4 所示。

(二) 实验结果

如图 5 所示，展示了在学习率设为 0.01、动量为 0.9 的配置下，DenseNet 在验证集上的表现。模型在第 17 个 epoch 触发早停，最终准确率稳定在约 80%，显著优于基础 CNN，略逊于 ResNet18，并成功收敛，其中最佳准确率是 80.05%。这里曲线变化较为正常，符合预期。

五、 SE-ResNet

(一) 网络结构




图 6: SE-ResNet 的架构图




图 7: SE-ResNet18 在验证集上的损失与准确率

如图 6 所示, Squeeze-and-Excitation (SE) 模块通过显式建模通道之间的依赖关系, 提升了特征表示能力。该模块首先对输入特征图 $x \in \mathbb{R}^{c \times h \times w}$ 进行全局平均池化 (Global Pooling), 生成一个通道维度的描述向量 ($c \times 1 \times 1$), 用于捕捉全局上下文信息。接下来, 通过两个全连接层 (FC) 构建出一个非线性通道注意力机制。第一个 FC 层将通道数降为 $\frac{c}{r}$ (其中 r 为压缩比, 常设为 16), 然后再通过 ReLU 激活后接一个 FC 层恢复至原始通道数 c , 最后通过 Sigmoid 函数输出通道注意力权重。这些权重将与原始特征图按通道进行逐元素乘法 (Scale) 以完成特征重标定。该过程不会改变空间结构, 但会动态调整各通道的重要性。在 SE-ResNet 中, SE 模块被插入到每个 ResNet 的残差单元中, 具体方式为: 对残差分支的输出进行通道加权后再与主分支进行相加操作。相比原始 ResNet, SE-ResNet 在参数量和计算量几乎不变的情况下, 能显著提升模型性能。

这里我选择将 SE 模块结合上文中的 ResNet18 进行后续实验。

(二) 实验结果

如图 7 所示, 在与前文相同的实验设置下, SE-ResNet18 在相同训练轮数内取得了更低的损失和更高的准确率, 最佳验证准确率为 84.34%。尽管表现略优于 ResNet18, 但整体提升幅度较小, 可能由于 CIFAR-10 数据集任务较简单, 尚不足以充分发挥 SE 模块的通道注意力机制优势。在第 10 个 epoch 即触发早停, 模型快速收敛, 训练过程稳定。

六、网络结构对比分析

实验设置 为确保不同模型之间的公平对比, 实验统一设置学习率为 0.01、动量为 0.9。此外, 为排除早停机制对训练轮数的影响, 本实验关闭了早停功能, 所有模型均训练固定的 20 个 epoch, 以便更准确地比较其收敛趋势与最终性能。

模型性能 从图 8 可以看出, 相较于基础 CNN 网络, 其余三种改进型网络在验证集上的表现均有明显提升。以验证准确率为例, 基础 CNN 最终准确率仅为约 65%, 而 SE-ResNet18、DenseNet 和 ResNet18 均超过了 80%, 其中 ResNet18 和 SE-ResNet18 达到了约 85% 的最高准确率。值得注意的是, 在验证损失方面, ResNet18 和 SE-ResNet18 的 loss 曲线反而高于 DenseNet 和 MobileNet。这一“高准确率但高 loss”的现象, 通常是由于模型在训练后期对少数样本产生过度置信, 从而在错误预测上造成更大的损失。尤其是 SE-ResNet18 由于引入了通道注意力机制, 模




图 8: 4 种 CNN 网络在验证集上的损失与准确率

型对“关键通道”响应更加敏感，在提升准确率的同时，也可能放大了对错误样本的判断偏差，导致验证损失上升。这反映出模型虽然整体预测更准确，但对错误样本更“自信”，进而引发轻微的过拟合倾向。综合来看，ResNet18 与 SE-ResNet18 在准确率方面表现最佳，而 DenseNet 在损失收敛速度与稳定性上更优，MobileNet 则在性能与计算效率之间取得较好平衡。

训练时间 ResNet18、DenseNet 和 SE-ResNet18 的网络深度分别为 18 层、22 层和 18 层，整体参数量较多。由于计算资源有限，所有模型均在单卡 GPU 上进行训练，统一训练 20 个 epoch。从实际运行情况来看，ResNet18 与 SE-ResNet18 的训练时间最长，其中 SE-ResNet18 因引入通道注意力机制，计算量略有增加，训练速度略慢于 ResNet18。而 DenseNet 与基础 CNN 的训练时间明显更短。DenseNet 虽然结构较复杂，但由于每层通道较窄，参数量远小于 ResNet，同时其全连接层也更轻量，因此整体训练速度较快。基础 CNN 结构最简单，参数最少，训练最快，基本可以视为基线参考。

总结 实现的 ResNet18 网络在整体性能上相较于原始 CNN 有显著提升。其主要优势在于通过残差连接引入深层结构，在有效增加网络深度的同时缓解了梯度消失问题，从而提升了特征提取能力和模型的收敛稳定性。DenseNet 则采用密集连接机制，每一层都与后续所有层相连，这种设计在特征复用和梯度流动方面效果显著，使得网络在保持较少参数量的同时具备较强的表达能力。

SE-ResNet18 在 ResNet18 的基础上引入了 Squeeze-and-Excitation 模块，引入通道注意力机制，提升了模型对重要特征通道的响应能力。尽管其验证准确率略高于 DenseNet（提升约 1.2%），但验证损失曲线明显高于其他模型，可能存在轻度过拟合。此外，由于增加了额外的全连接运算，训练时间也略有延长。

综合准确率、loss 曲线走势、训练效率等因素，本文认为在所实现的三种改进 CNN 结构中，DenseNet 综合表现最为优秀。其准确率与 ResNet18 接近，但训练稳定性更好、收敛更快，同时未出现明显过拟合情况，表现出较强的实际适应能力。因此，在当前实验设置下，DenseNet 是最具性价比的模型结构。

七、 扩展: Res2Net

(一) 网络结构




图 9: Res2Net 的架构图

如图 9 所示, Res2Net 在经典 ResNet 的 Bottleneck 基础上进行了结构扩展, 核心思想是在单个残差块内部引入多尺度特征表达机制。具体地, 在经过第一层 1×1 卷积后, 特征图被均匀划分为 s 个通道子集, 分别记为 $x_1, x_2, \dots, x_s$ 。其中 x_1 直接跳过卷积作为恒定通路, 其余子集则依次通过不同的 3×3 卷积 (记作 $K_i(\cdot)$) 进行处理, 并引入类残差式的逐级连接方式。每个子集 x_i 的输入不仅包括当前通道, 还会与上一个卷积的输出 y_{i-1} 相加后再传入 $K_i(\cdot)$ 。即:

$$y_i = K_i(x_i + y_{i-1}), \quad \text{for } i \geq 2$$

该结构在保持参数量可控的同时, 实现了对多个感受野尺度的组合建模, 从而增强了特征表达能力。

最终所有子分支的输出 $\{y_1, y_2, \dots, y_s\}$ 在通道维度上进行拼接, 并通过一个 1×1 卷积进行融合, 作为残差块的输出结果。

相较于传统的 Bottleneck 块, Res2Net 模块能够在一个残差单元内表示更丰富的多尺度特征, 不依赖堆叠更深的层数。这种设计也可被无缝集成进 ResNet、ResNeXt、DLA 等主流骨干网络中, 用于提升分类、检测和分割等任务的性能表现。这里我们仍使用分类任务来进行性能评估

(二) 实验结果

如图 10 所示, Res2Net 模型在验证集上的表现优于前述所有网络。模型在训练初期迅速收敛, 在后期保持稳定提升, 最终准确率达到 86.43%, 是所有实验网络中的最高值。同时, 其验证集 loss 曲线整体较为平稳, 波动虽略大, 但仍维持在较低水平, 显示出较强的收敛能力和泛化能力。这说明 Res2Net 的多尺度特征建模机制在图像分类任务中能够有效提升模型的判别能力。

模型对比分析 与其他三种 CNN 结构相比, Res2Net 具备如下优势与劣势:

- **与原始 CNN 相比:** Res2Net 引入了深层残差结构和多尺度分支, 使得特征表达能力大幅增强, 在准确率和收敛速度上均远超原始 CNN。
- **与 ResNet18 相比:** Res2Net 在每个残差块内部构建了细粒度的多尺度表示, 使得单个 block 具有更大的感受野和更强的特征多样性, 从而进一步提升分类性能。但由于结构更复杂, 训练时间略长, 计算开销略大。




图 10: Res2Net18 在验证集上的损失与准确率

- **与 DenseNet 相比:** Res2Net 同样强调特征重用, 但其采用的分组卷积与分支融合策略更加轻量, 能在保持高性能的同时控制参数规模。此外, Res2Net 在准确率上优于 DenseNet, 收敛速度也更快。
- **与 SE-ResNet 相比:** 两者都在残差结构上引入增强机制。SE 模块强调通道重要性, Res2Net 则增强了空间层次感视野。实验结果表明, Res2Net 的多尺度机制在当前任务中带来了更大的性能提升。但 SE 模块结构更简单, 训练更稳定, 因此在某些任务中也有一定优势。

综上所述, Res2Net 凭借其在单个 block 内实现多尺度建模的能力, 在本实验中取得了最优的性能表现, 展现出极高的应用潜力。

八、实验心得

通过本次实验, 我已较为熟练掌握了 PyTorch 框架中基础算子 (如卷积、池化、激活函数等) 的使用, 并能够独立构建更复杂的神经网络结构, 不再局限于原始的卷积网络。实验中我成功复现了 ResNet、DenseNet 和 SE-ResNet 等主流模型, 并进一步探索了 Res2Net 模型, 并在 CIFAR-10 数据集上完成了图像分类任务。

通过对比不同网络在实际任务中的表现, 我深入理解了各类架构的设计思路与性能差异, 并意识到在实际应用中, 根据任务特点选择合适的网络结构与超参数设置是实现良好性能的关键。此外, 实验过程中遇到的一些问题也促使我对模型设计和训练策略进行了进一步思考。

未来, 我希望能继续探索更先进的网络结构及优化技巧, 以进一步提升模型在各类任务中的表现。

参考文献

- [1] Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. Imagenet: A large-scale hierarchical image database. In *CVPR*, 2009.
- [2] Shang-Hua Gao, Ming-Ming Cheng, Kai Zhao, Xin-Yu Zhang, Ming-Hsuan Yang, and Philip Torr. Res2net: A new multi-scale backbone architecture. *TPAMI*, 2019.
- [3] K. He, X. Zhang, S. Ren, and J. Sun. Deep residual learning for image recognition. In *CVPR*, 2016.
- [4] Jie Hu, Li Shen, and Gang Sun. Squeeze-and-excitation networks. In *CVPR*, 2018.
- [5] Gao Huang, Zhuang Liu, Laurens Van Der Maaten, and Kilian Q Weinberger. Densely connected convolutional networks. In *CVPR*, 2017.
- [6] Alex Krizhevsky. Learning multiple layers of features from tiny images. Technical report, Citeseer, 2009.
- [7] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E Hinton. Imagenet classification with deep convolutional neural networks. In *NeurIPS*, 2012.
- [8] Karen Simonyan and Andrew Zisserman. Very deep convolutional networks for large-scale image recognition. In *ICLR*, 2015.