



南开大学  
Nankai University

南 开 大 学

计 算 机 学 院

深度学习实验报告

---

## 生成对抗网络

---

2112213 冯思程

年级：2021 级

专业：计算机科学与技术

指导教师：侯淇彬

2025 年 5 月 29 日

## 摘要

本文主要研究了生成对抗网络 GAN 的原理及其在 Fashion-MNIST 数据集上的应用。通过使用 PyTorch 框架，我构建了一个基础的 GAN，并对其进行了训练和优化。此外，我还探讨了不同随机数对生成结果的影响，并进一步实现了基于 CNN 的 GAN (DCGAN)，以提高生成图像的质量。实验结果表明，基于 CNN 的 GAN 在图像生成质量上有显著提升。本实验不仅加深了我对 GAN 原理的理解，也展示了深度学习在图像生成领域的强大应用潜力。

**关键字：**生成对抗网络, GAN, DCGAN, PyTorch, FashionMNIST, 卷积神经网络, 图像生成

## 目录

|                         |          |
|-------------------------|----------|
| <b>一、 研究背景与准备</b>       | <b>1</b> |
| (一) 研究背景 . . . . .      | 1        |
| (二) 数据集 . . . . .       | 1        |
| (三) 实验设置 . . . . .      | 1        |
| <b>二、 基础 GAN</b>        | <b>1</b> |
| (一) 网络结构 . . . . .      | 1        |
| (二) 实验 . . . . .        | 2        |
| 1. 损失分析 . . . . .       | 2        |
| 2. 生成效果分析 . . . . .     | 3        |
| 3. 消融实验：调整随机数 . . . . . | 3        |
| <b>三、 DCGAN</b>         | <b>4</b> |
| (一) 网络结构 . . . . .      | 4        |
| (二) 实验结果与分析 . . . . .   | 4        |
| <b>四、 实验心得</b>          | <b>5</b> |

## 一、研究背景与准备

### (一) 研究背景

生成对抗网络 (Generative Adversarial Networks, GANs) 由 Goodfellow 等人在 2014 年首次提出 [2], 其核心思想是通过生成器与判别器之间的博弈学习数据分布。生成器尝试生成以假乱真的样本以欺骗判别器, 而判别器则努力区分真实样本与生成样本。在这种对抗式训练机制下, 生成器逐步提高生成样本的质量, 从而实现无监督学习下的高质量样本建模。

尽管基础 GAN 模型在图像生成领域取得了初步成功, 但其训练过程常常不稳定, 容易出现梯度消失或模式崩溃等问题。为改善这一问题, Radford 等人提出了深度卷积生成对抗网络 (Deep Convolutional GAN, DCGAN) [6], 将卷积神经网络结构引入生成器与判别器中, 大幅提升了训练稳定性和生成图像的质量。DCGAN 秉持结构简洁、无池化、仅用卷积替代池化与上采样等设计原则, 成为后续大量 GAN 改进模型的基础框架。

随着研究的深入, 越来越多针对生成效果与训练稳定性的改进被提出。例如, Wasserstein GAN (WGAN) [1] 通过引入 Earth Mover 距离优化目标函数, 显著缓解了训练不稳定问题; Progressive GAN [3] 采用逐步增长图像分辨率的训练策略, 提升了高分辨率图像的生成质量; StyleGAN 系列 [4,5] 则通过风格控制与渐变融合机制, 在人脸等复杂图像生成任务上表现卓越。

本文以 Fashion-MNIST 图像生成任务为实验背景, 分别实现了基础 GAN 与 DCGAN 两类模型, 比较其在小规模灰度图像生成任务中的表现, 为后续结构优化与样本可控生成研究提供实验基础。

### (二) 数据集

本研究使用的实验数据集为 Fashion-MNIST。该数据集包含 10 个服装类别, 每个类别提供 6000 张训练图像和 1000 张测试图像, 图像尺寸均为  $28 \times 28$  像素。数据集中共划分为 10 类, 分别为: T-shirt/top、Trouser、Pullover、Dress、Coat、Sandal、Shirt、Sneaker、Bag 和 Ankle boot。

### (三) 实验设置

本实验使用 PyTorch 实现, 并以 Fashion-MNIST 数据集为基础进行图像生成任务。Fashion-MNIST 数据集包含 10 类服饰图像, 每类包含 6000 张训练样本和 1000 张测试样本, 图像尺寸为  $28 \times 28$ , 在输入模型前统一进行归一化处理 (均值 0.5, 标准差 0.5)。

实验分别构建了两类 GAN 结构: 其一为原始版本的 GAN, 采用多层感知机 (MLP) 结构构建生成器与判别器; 其二为卷积版本的 DCGAN, 使用卷积层与反卷积层构建生成器和判别器。训练过程中, 使用的优化器为 Adam, 学习率设为 0.0002, 批大小为 64, 噪声维度设为 100, 训练轮数为 10, 损失函数采用二元交叉熵 (BCELoss)。此外, 为便于观察模型效果, 生成阶段使用固定随机种子 (设为 42) 生成一致的噪声输入, 并在各轮保存对应输出图像, 以对比生成效果随训练进度的变化。实验还通过扰动噪声向量的特定维度, 进一步分析了噪声在生成图像中的控制作用。整个实验过程均在单张 RTX 4090 GPU 上完成, 训练效率高、性能表现稳定。

## 二、基础 GAN

### (一) 网络结构

Discriminator(




图 1: 基础 GAN 的损失

```

(fc1): Linear(in_features=784, out_features=128, bias=True)
(nonlin1): LeakyReLU(negative_slope=0.2)
(fc2): Linear(in_features=128, out_features=1, bias=True)
)
Generator(
  (fc1): Linear(in_features=100, out_features=128, bias=True)
  (nonlin1): LeakyReLU(negative_slope=0.2)
  (fc2): Linear(in_features=128, out_features=784, bias=True)
)

```

上述为本实验中使用的基础 GAN 网络结构。其中，生成器 (Generator) 以维度为 100 的随机噪声向量作为输入，经过两层全连接层和 LeakyReLU 激活函数后输出尺寸为  $28 \times 28 = 784$  的向量，并通过 reshape 还原为图像格式。输出层使用 tanh 激活函数，将生成图像的像素值限制在  $[-1, 1]$  范围内。

判别器 (Discriminator) 结构也较为简洁，由两层全连接层组成。其输入为展开后的图像向量 (784 维)，通过 LeakyReLU 激活函数和最后一层的 Sigmoid 输出，给出图像为真实的概率。该结构适用于像 MNIST 或 Fashion-MNIST 这类尺寸较小的灰度图像生成任务。

## (二) 实验

### 1. 损失分析

如图 1，在训练过程中，判别器和生成器的损失变化呈现出一定的规律性。对于判别器而言，训练初期由于生成样本质量较差，其很容易区分真实样本与生成样本，因此损失迅速下降。随着生成器逐渐提升生成效果，判别器面临更大的判别挑战，损失开始上升并在训练后期趋于波动，表明判别器已进入相对平衡的状态，能够稳定地区分真实与伪造样本。相比之下，生成器的损失通常在初期较高，因为生成的样本质量差，容易被判别器识别。然而，在本实验的原始全连接 GAN 中，生成器的初始损失并未显著偏高，可能是由于判别器收敛较快，导致生成器一开始难以有效学习。相比之下，在采用卷积结构构建的 GAN 中，生成器的损失变化更符合预期，初期较高、随后逐步下降并在训练后期趋于稳定，说明生成器逐步学会生成更具真实感的图像（见后文）。整体而言，损失曲线的走势反映了生成器与判别器之间不断博弈与协同优化的过程。




图 2: 生成器 Inference 的图片




图 3: 调整随机数不同维度生成的图像变化

## 2. 生成效果分析

在本实验中，我自定义了一组服从标准正态分布的随机噪声，并将其输入生成器以生成 8 张图像，结果如图 2 所示。从图中可以看出，生成的图像整体较为模糊，缺乏清晰的结构特征，尚未呈现出明显的服装形状。这说明此时生成器的效果较差，尚未充分学习到目标数据的分布。

## 3. 消融实验：调整随机数

本实验选择噪声向量中的第 20、50、60、70 和 90 维进行调整，观察其对生成图像的影响，结果如图 3 所示。图 2 展示了原始（未调整）情况下生成的图像。对于调整后的图像，每一列对应一个被修改的维度，第一行为该维度增加 2，第二行为增加 5，第三行为减少 5。

通过对比图 2 和图 3，可以清晰地观察到：不同维度的随机数在不同程度上影响了生成图像的外观属性。例如，第 20 维主要影响衣袖的长度，值越大衣袖越短；第 50 维则与图像整体的亮度或“颜色深浅”相关；第 60 与第 70 维都影响图像的明暗程度，但第 60 维的影响更为显著；而第 90 维则作用于图像的纹理细节，其值越小纹理越清晰。

这些现象表明：输入噪声向量中的不同维度被生成器学习为控制图像中不同类型的属性——包括形状（如衣袖）、明暗（如颜色或亮度）以及纹理等。换句话说，生成器在训练过程中已将




图 4: DCGAN 的损失

输入向量的不同维度“映射”到了图像空间中不同的特征因子上。与此同时，调整幅度越大，生成图像的变化越明显，进一步验证了生成器对于输入噪声的响应具有较好的连续性与可控性。

这一现象体现了生成模型的可解释性与可控性，也为后续的属性引导生成或潜空间分析提供了基础。

### 三、 DCGAN

#### (一) 网络结构

```
CNNDiscriminator(
    (conv_layer1): Conv2d(1, 64, kernel_size=4, stride=2, padding=1)
    (activation1): LeakyReLU(0.2)
    (conv_layer2): Conv2d(64, 128, kernel_size=4, stride=2, padding=1)
    (batch_norm2): BatchNorm2d(128)
    (activation2): LeakyReLU(0.2)
    (dropout_layer): Dropout(0.3)
    (fc_layer): Linear(6272 -> 1)
)

CNNGenerator(
    (deconv_layer1): ConvTranspose2d(100 -> 256, kernel_size=7)
    (batch_norm1): BatchNorm2d(256)
    (activation1): ReLU()
    (deconv_layer2): ConvTranspose2d(256 -> 128, kernel_size=4, stride=2, padding=1)
    (batch_norm2): BatchNorm2d(128)
    (activation2): ReLU()
    (deconv_layer3): ConvTranspose2d(128 -> 1, kernel_size=4, stride=2, padding=1)
)
```

相比于基础的全连接 GAN，这里的 DCGAN 模型使用卷积和反卷积构建判别器和生成器，能够更好地提取局部特征、提升生成图像的质量和训练的稳定性。其中判别器通过两层卷积提取图像特征并分类真假，生成器则通过三层反卷积将噪声逐步还原为图像，更适合处理图像类生成任务。

#### (二) 实验结果与分析

根据前述实验结果，模型的损失曲线如图 4 所示。相比基础 GAN，基于 CNN 构建的 GAN 在训练过程中表现出更平稳的损失变化，且整体 Loss 值更低，表明其训练过程更稳定、生成效果更可靠。



图 5: DCGAN 生成器 Inference 的图片

图 5 展示了 CNN-GAN 生成的图像示例。可以明显看出，其生成的图像更加清晰、结构更自然，更接近真实的服装样式。这一结果表明，引入卷积结构显著提升了模型对图像局部特征的建模能力，从而增强了生成图像的质量和可辨识度。

## 四、 实验心得

通过本次实验，我深入掌握了生成对抗网络（GAN）的基本原理，并成功使用 PyTorch 构建了一个用于训练 FashionMNIST 数据集的 GAN 模型。在实践过程中，我观察到不同的随机种子会对生成图像的特定特征产生显著影响，例如形状、纹理或颜色等方面的变化。此外，我还实现了一个基于卷积神经网络（CNN）的改进版 GAN，并在生成效果上明显优于原始结构，表明引入 CNN 能有效提升模型的生成质量与稳定性。



## 参考文献

- [1] Martin Arjovsky, Soumith Chintala, and Léon Bottou. Wasserstein generative adversarial networks. In *ICML*, 2017.
- [2] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial nets. In *NeurIPS*, 2014.
- [3] Tero Karras, Timo Aila, Samuli Laine, and Jaakko Lehtinen. Progressive growing of gans for improved quality, stability, and variation. In *ICLR*, 2018.
- [4] Tero Karras, Samuli Laine, and Timo Aila. A style-based generator architecture for generative adversarial networks. In *CVPR*, 2019.
- [5] Tero Karras, Samuli Laine, Miika Aittala, Janne Hellsten, Jaakko Lehtinen, and Timo Aila. Analyzing and improving the image quality of stylegan. In *CVPR*, 2020.
- [6] Alec Radford, Luke Metz, and Soumith Chintala. Unsupervised representation learning with deep convolutional generative adversarial networks. *arXiv preprint arXiv:1511.06434*, 2015.