



南開大學
Nankai University

南 開 大 學

計 算 機 學 院

深度學習實驗報告

顯著性物體檢測

2112213 馮思程 2212915 李天蔚 2210961 馮子函

年級：2021 級

專業：計算機科學與技術

指導教師：侯淇彬

2025 年 6 月 22 日

摘要

本文复现并优化了三种显著性物体检测模型：RASNet、PiCANet 和 PFANet，并在 EC-SSD 数据集上进行了系统评估。实验包括原始模型复现、结构与损失函数优化，以及完整的消融对比分析。结果显示，引入金字塔池化、边界注意力和联合损失可有效提升 RASNet 表现，而 PiCANet 通过注意力层级结构与非局部模块的组合达到了最优性能。各模型在精度、边缘保留与计算开销之间展现出不同权衡。未来可进一步研究轻量化结构、多任务融合和推理模型等方向，以拓展模型在复杂场景中的适应性与实际应用潜力。

关键字：显著性物体检测，RASNet，PiCANet，PFANet，ReNet，ResNet，注意力机制，消融实验

目录

一、 研究背景与准备	1
(一) 研究背景	1
(二) 数据集	1
(三) 小组分工	1
(四) Gitee	1
二、 RASNet	1
(一) 主干网络与多层特征融合	1
(二) 多尺度残差特征与分辨率提升	2
(三) 输出与监督机制	3
三、 PiCANet	3
四、 PFANet	4
(一) 上下文感知金字塔特征提取	4
(二) 注意力机制	4
五、 模型优化	5
(一) RASNet	5
1. 边界注意力模块	5
2. 金字塔池化模块	5
3. 优化联合损失	6
(二) PiCANet	6
1. CBAM + SEBlock 融合的注意力机制层级结构	6
2. 非局部注意力模块嵌入	7
六、 实验	7
(一) 实验设置	7
(二) 实验结果	8
(三) 消融实验	9
七、 未来设想与实验心得	11

一、 研究背景与准备

(一) 研究背景

显著性物体检测 [1,2,8] (Salient Object Detection, SOD) 旨在识别图像中最引人注意的区域或物体,是计算机视觉中的基础任务,广泛应用于图像分割、目标跟踪和图像压缩等领域。随着深度学习的发展,基于卷积神经网络(CNN)的显著性检测方法迅速崛起,取得了显著性能提升。早期方法多以 VGG [16]、ResNet [5] 等为骨干网络,提取多尺度特征以提升定位精度。

近年来,研究者提出了多种具有代表性的 SOD 网络结构以加强空间上下文建模与注意力机制。PiCANet [11] 引入了像素级注意力机制,在不同尺度上捕捉全局上下文信息。Reverse Attention [4] 则通过“反向学习”机制,强调显著区域与背景的边界信息,提升边缘细节刻画能力。为了提升多尺度特征融合效果,PFANet [22] 设计了金字塔注意力模块,增强不同层级之间的特征互补。而 PoolNet [10] 以简洁高效的池化模块实现了更优的实时性能。此外,ViT 架构的引入推动了显著性检测向 Transformer 方向拓展,Visual Saliency Transformer (VST) [12] 通过全局建模能力显著提升了复杂场景下的检测效果。Integrity Learning [21] 则引入一致性学习框架,从预测一致性的角度优化检测过程。

本研究综合评估了上述部分代表性模型在多个标准数据集上的性能,旨在分析不同结构设计对于显著性目标检测精度、边缘保留能力和计算效率的影响。

(二) 数据集

CSSD (Complex Scene Saliency Dataset) 是一个用于显著性检测研究的小型数据集,旨在评估模型在复杂背景下的表现 [19]。然而,该数据集规模较小,限制了在更广泛场景中的应用。为此,作者在后续工作中将 CSSD 扩展为更大规模的 ECSSD (Extended Complex Scene Saliency Dataset),共包含 1000 张图像,涵盖更多语义丰富、结构复杂的自然场景 [15]。这些图像主要从互联网收集,并由 5 位标注者手工标注生成高质量的真值掩码,适用于显著性检测模型在多样环境下的评估。我们本研究采用的主要数据集即为 ECSSD。其中我们随机划分其中 700 张为训练集,剩余 300 张为测试集,并在后续实验中固定训练和测试集的划分以保证结果对比公平性。

(三) 小组分工

1. 冯思程 (队长): PiCANet 复现、大部分实验测试、部分 RASNet 优化、部分 PiCANet 优化、文档撰写。
2. 李天蔚 (队员): RASNet 复现、少部分实验测试、部分 RASNet 优化、少部分文档撰写。
3. 冯子函 (队员): PFANet 复现、少部分实验测试、部分 PiCANet 优化、少部分文档撰写。

(四) Gitee

我们在 Gitee 平台进行代码维护,目前所有代码均已提交并推送到平台上 (Link: [DL_Final](#))。

二、 RASNet

(一) 主干网络与多层特征融合

RASNet [4] 采用 VGG 网络作为主干特征提取网络。如图 1 所示,具体而言,从 VGG 的不同层提取多个侧边输出,分别为 conv1_2, conv2_2, conv3_3, conv4_3, conv5_3,并一直




图 1: RASNet 网络结构 [4]

提取到 pool5 层为止。

输入图像首先进入 VGG 主干网络,通过逐层卷积和池化操作提取特征。在 conv1_2,conv2_2, conv3_3, conv4_3, conv5_3 这五个关键层, 分别提取中间特征, 作为侧边输出 (即 s-out 1、s-out 2、s-out 3 等)。在 pool5 层输出后, 采用 1×1 卷积将通道数降至 256。接着, 在降维后的特征上连接 3 层 5×5 的卷积, 以捕获更大感受野的全局显著性图 (global saliency maps)。由于全局显著性图的分辨率仅为输入图像的 $1/32$, 因此后续还需逐步提升其空间分辨率。

侧边输出的卷积层和全局显著的卷积层配置如表 1 所示:

Side output 1~5	Global saliency
(64, 1×1)	(256, 1×1)
$\{(64, 3 \times 3), \text{ReLU}\} \times D$	$\{(256, 5 \times 5), \text{ReLU}\} \times 3$
(1, 3×3)	(1, 1×1)

表 1: RASNet 配置 [4]

(二) 多尺度残差特征与分辨率提升

由于全局显著性 maps 分辨率很低 ($1/32$), 直接上采样会导致显著区域边界模糊, 信息损失。因此, RASNet 设计了一套逐步残差学习与上采样机制:

- 侧输出残差特征学习: 在每个侧输出 (如 s-out 1/2/3 等) 后, 均引入反向注意块 (Reverse Attention Block), 用于增强对显著目标边界、细节的刻画。
- 反向注意块输出后, 接 D 层 (D 可设为 13 层) 3×3 卷积, 通道数为 64, 进一步学习丰富的边界和细节残差信息。
- 残差特征通过与上一层上采样的显著图进行逐步融合。每一级融合输出都通过上采样 (如 $\text{up} \times 2/4/8$ 等) 提升分辨率, 并将全局和局部信息叠加。




图 2: PiCANet 网络结构 [11]

(三) 输出与监督机制

最终，在所有融合残差特征后，得到一张和输入图像等尺寸的显著性预测图。通过 sigmoid 激活函数，输出显著性概率图。为了优化各层特征表达和网络梯度流动，RASNet 在每一级都引入了深度监督 (Deep Supervision)，即每个阶段都对输出分支进行监督，与真实显著图 (Ground truth) 做损失回传。

三、PiCANet

PiCANet [11] 网络架构分层地采用 PiCANets 来进行显著性目标检测。整个网络基于 U-Net 架构，U-Net 的编码器部分是一个带有预训练主干网络的 FCN，以保持特征图的分辨率。解码器遵循 U-Net 的思想，使用跳跃连接，并嵌入了全局和局部 PiCANets。

如图 2 所示，PiCANet 是一种新颖的逐像素上下文注意力网络，对于每个像素，该网络可生成一个注意力图，其中每个注意力权重对应各个上下文位置的上下文相关性。随后，通过选择性聚合上下文信息，能够构建出经注意力机制处理的上下文特征。

PiCANet 设计为全局和局部两种形式，分别用于捕捉全局和局部上下文。全局 PiCANet 有助于学习全局对比度，局部 PiCANet 则利于学习局部同质性。

为了让每个像素能够首先“看到”整个特征图 F ，PiCANet 采用复合网络架构，其感受野覆盖整幅图像。PiCANet 采用了更有效且高效的 ReNet [18] 模型，该模型使用四个循环神经网络分别在水平和垂直方向上双向扫描图像，以融合全局上下文信息。

接下来，PiCANet 使用一个普通的卷积层将 ReNet 特征图转换为 D 个通道，其中 $D = W \times H$ 。然后，在每个像素位置 (w, h) ，得到特征向量 $x_{w,h}$ ，并通过 softmax 函数对其进行归一化，以生成全局注意力权重 $\alpha_{w,h}$ 。

最后，对于像素 (w, h) ，特征图 F 中所有位置的特征通过 $\alpha_{w,h}$ 进行加权求和，以构建注意力增强的上下文特征。




图 3: PFANet 上下文感知金字塔特征提取模块 [22]

对于局部注意力，在每个像素 (w, h) 处，PiCANet 仅在一个以 (w, h) 为中心的局部邻域上下文区域上执行注意力操作。

首先需要让每个像素“看到” $\bar{W} \times \bar{H}$ 的上下文区域。然后，与全局 PiCANet 相同，使用一个卷积层将结果特征图变换为 $\bar{D}$ ($\bar{D} = \bar{W} \times \bar{H}$) 个通道。接下来，局部注意力权重也通过 softmax 归一化生成。最后，对于像素 (w, h) ， $\bar{F}^{(w, h)}$ 中的特征通过 $\bar{\alpha}^{(w, h)}$ 加权求和得到 F_{atto} 。

四、 PFANet

(一) 上下文感知金字塔特征提取

PFANet [22] 设计了一种新的模块来提取尺度、形状和位置不变性的特征（图 3）。类似于尺度不变特征变换中的高斯函数，PFANet 使用 Atrous 卷积来获得尺度相同但接收范围不同的特征。类似于 SIFT 中的金字塔多分辨率表示，PFANet 采用 Conv 3-3、Conv 4-3 和 Conv 5-4 来提取多尺度特征并将其作为基本的高层特征。为了使最终提取的高层特征包含尺度不变性和形状不变性特征，PFANet 采用不同扩张率的 Atrous 卷积，分别设置为 3、5 和 7 来捕捉多感受场上下文信息。然后，通过跨通道级联，将来自不同 Atrous 卷积层的特征图与 1×1 降维特征进行拼接。然后利用上下文感知信息得到三种不同尺度的特征，将两个较小的特征向上采样为最大的一个。最后，PFANet 将它们进行跨通道级联，作为上下文感知金字塔特征提取模块的输出。

(二) 注意力机制

根据不同层次特征的特点，PFANet 对高级特征采用通道式关注和空间关注度的选择，以选择有效的特征。此外，PFANet 不将空间注意力用于高级特征，因为高级特征包含较高的抽象语义，因此不需要过滤空间信息。而对于低层特征，PFANet 没有使用通道注意，因为低层特征的不同通道之间几乎没有语义差异。




图 4: BAM 整体结构 [9]

五、模型优化

(一) RASNet

我们在主干 RASNet 的基础上，分别引入了金字塔池化模块（PPM）[6]、边界注意力模块（BAM）[9] 以及联合 BCE+Dice 损失。PPM 模块通过多尺度池化获取不同空间层次的全局上下文，有效增强 RASNet 对复杂场景及多尺度目标的分割能力。BAM 模块通过生成边缘注意力权重图，显著提升了 RASNet 分割轮廓的清晰度和准确度。损失函数方面，BCE 与 Dice 联合，兼顾了像素级准确度和整体区域一致性，使 RASNet 分割结果更加精细与鲁棒。

1. 边界注意力模块

BAM(Bottleneck Attention Module) [9] 是一种用于计算机视觉领域的深度学习模型结构，它旨在提高神经网络对图像的特征提取和感受野处理能力。BAM 模块引入了通道注意力机制，能够自适应地加强或减弱不同通道的特征响应，从而提高了模型的性能。BAM 的整体结构如图 4所示：

BAM 模块由两个关键组件组成：通道注意力机制和空间注意力机制：

- 通道注意力机制用于自适应地调整每个通道的特征响应，基本结构包括全局平均池化，并将每个通道的全局平均池化结果通过两个全连接层传递。这些全连接层用于学习如何加权每个通道的特征响应。在全连接层之后，通过 Sigmoid 激活函数将输出限制在 0 到 1 之间，以表示每个通道的权重。这些权重用于调整通道特征响应。将通道的特征响应与学习到的通道权重相乘，从而得到加权后的通道特征响应。
- 空间注意力机制用于处理不同空间位置的特征。其基本结构与通道注意力机制类似，包括全局最大池化、两个全连接层以及 Sigmoid 激活函数。全局最大池化操作将每个通道的特征图池化为一个标量值，表示该通道特征的局部重要性。两个全连接层用于学习如何加权每个通道的特征响应。Sigmoid 激活函数将输出限制在 0 到 1 之间，表示每个通道的权重。这些权重用于调整通道特征响应。最后，将通道的特征响应与学习到的空间权重相乘，得到加权后的通道特征响应。

BAM 让 RASNet 对边界区域更加敏感，从而提升分割输出的边缘质量（锐利且准确）。

2. 金字塔池化模块

PPM(Pyramid Pooling Module) [6] 是一种特殊的池化模型。通过由多到少的池化，可以有效增大感受野，增大全局信息的利用效率。在很多网络中，我们都很重视全局信息的获取。如图 5 (a)




图 5: PPM [6]

所示，没有充分利用好场景的上下文信息会有 Mismatched Relationship, Confusion Categories, Inconspicuous Classes 等问题。

PPM 就是一种相对较好的充分利用全局信息的方式。如图 5 (b) 所示，金字塔池化模块的层数是 4 层，每层的 size 分别是 $1 \times 1, 2 \times 2, 3 \times 3, 6 \times 6$ 。首先，对特征图分别池化到目标 size，然后对池化后的结果进行 1×1 卷积将 channel 减少到原来的 $1/N$ ，这里 N 就为 4。接着，对上一步的每一个特征图利用双线性插值上采样得到原特征图相同的 size，然后将原特征图和上采样得到的特征图按 channel 维进行 concatenate。得到的 channel 是原特征图的 channel 的两倍，最后再用 1×1 卷积将 channel 缩小到原来的 channel。最终的特征图和原来的特征图 size 和 channel 是一样的。

PPM 通过多尺度的全局上下文特征汇聚，极大丰富了深层特征的信息，增强了 RASNet 对不同物体尺度的感知能力。

3. 优化联合损失

Dice Loss 是一种基于 Dice 系数的损失函数，主要用于图像分割任务，尤其适用于处理类别不平衡的数据集。其核心公式为：

$$\mathcal{L}_{\text{Dice}} = 1 - \frac{2 \sum_{i=1}^N y_i \hat{y}_i + \epsilon}{\sum_{i=1}^N y_i + \sum_{i=1}^N \hat{y}_i + \epsilon}$$

BCE Loss(Binary Cross-Entropy Loss) 是用于二分类问题的损失函数。它用于评估预测值和实际标签之间的差异。其核心公式为：

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

在之前的优化中，PPM 提升了 RASNet 的区域整体感知能力，BAM 提升了 RASNet 前后景判别和细节关注，使得网络输出通常会在目标区域一致性和边界信息方面表现较好。Dice Loss 属于区域级损失，能够放大 PPM 和 BAM 在目标区分、目标一致性和全局感知方面的优点。BCE 结合 Dice Loss 兼顾像素准确性和区域一致性，在实际训练中更稳定。

(二) PiCANet

1. CBAM + SEBlock 融合的注意力机制层级结构

如图 6 (a) 所示，我们在解码阶段高层特征 (dec5, dec4) 使用了 CBAM (包含 channel + spatial attention)，中低层 (dec3) 使用了 SEBlock (channel attention)。




图 6: PiCANet 优化框架

相比于单一注意力模块，这种设计体现了注意力机制的分层使用：高层更关注显著区域位置 (spatial)，中层更关注语义通道 (channel)，使得模型既保留全局关注又不丢失细节语义，提升细节保留能力和目标边界感知能力。

2. 非局部注意力模块嵌入

如图 6 (b) 所示，在对 enc5 提取的高层语义特征进行通道统一后，加入了 Non-Local Block，引入了像素级别的全局上下文建模能力。Non-Local Attention 能够建模图像中远距离依赖关系，突破卷积局部感受野的限制；它特别适合处理像素间的非局部显著性关系，在视觉任务中非局部信息能更好建模显著性区域的全图依赖，能更精准地找出目标与背景的区别；并且这种 Non-Local 更轻量，适合集成到传统卷积结构中而不会显著增加计算量。

需要指出的是，上述两项优化并非各自独立显著提升性能，而是在联合使用时实现了互补增强。分层注意力机制有助于突出局部显著目标，而非局部注意力提供了全局一致性建模能力。两者协同，使模型在保持边缘细节的同时具备更强的全局感知能力，从而实现更精准、更稳健的显著性检测效果。

六、实验

(一) 实验设置

本实验基于 PyTorch 框架，在一张 RTX 4090 GPU 上完成训练与评估。训练阶段使用 Adam 优化器，初始学习率设为 $1e-4$ ，batch size 设为 4，训练轮数共计 30 轮。每轮训练后记录平均损失，选取损失最小的模型作为最终模型保存。测试阶段在独立划分的测试集上进行，评估指标包括 F-measure、平均绝对误差 (MAE) 以及平均精度 (AP)，并绘制 Precision-Recall 曲线及典型样本的可视化预测结果。整体流程包含模型训练、保存、加载与完整评估，覆盖从性能对比到可视化分析的全过程。其中训练数据我参考 RASNET 原文设置了随机水平翻转和随机旋转进行数据增强。额外地，为保证稳定，我们重复三次实验取均值得到结果。

表 2: 结果汇总表

Name	F-measure $\uparrow$	MAE $\downarrow$	Average Precision (AP) $\uparrow$	Training Time (s)
ResNet50	0.8264	0.0713	0.9350	240.68
RASNet	0.8308	0.0656	0.9301	254.67
PiCANet	0.8804	0.0506	0.9587	300.35
PFANet	0.8440	0.0725	0.9509	361.63
RASNet_OPT	0.8522 $\uparrow 0.0214$	0.0637 $\downarrow 0.0067$	0.9337 $\uparrow 0.0036$	267.60
PiCANet_OPT	0.8935 $\uparrow 0.0057$	0.0402 $\downarrow 0.0084$	0.9706 $\uparrow 0.0119$	320.67




图 7: PR 曲线

(二) 实验结果

从表 2 可见, 复现的三篇工作 (RASNET, PiCANet 和 PFANet) 均优于主干网络 ResNet50, 说明显著性检测任务对网络结构设计有较高依赖, 仅靠 backbone 难以获得优异性能。其中可以看到不同指标并不具有一致性, 如 PFANet 相对于 RASNet 有更高的 F-measure, 但 MAE 却差一些, 说明 PFANet 在目标区域的定位和边界重合上表现更好, 提升了整体精度和召回率, 但其像素级的预测值可能更模糊或偏离真实值, 导致误差增大。这反映了 PFANet 更擅长捕捉目标结构, 但在细节还原或数值精度上略逊一筹, 体现了 F-measure 和 MAE 衡量维度的不同。进一步, 观察到所有优化后的模型 (如 RASNET_OPT、PiCANet_OPT) 在 F-measure、MAE 和 AP 指标上均取得了全面提升, 验证了我们优化策略的有效性。整体来看, PiCANet_OPT 取得了最优表现, 展现出强大的检测能力与泛化能力。额外地, 我们记录了训练时间, 发现其中优化后的模型训练时间略微增加, 其中 PFANet 训练时间最长, 从整体上看, 这些模型均消耗 cost 很小, 这也与 GPU 的快速发展密切相关。同时, 图 7 展示了 PR 曲线同样符合上述结论, 其中 PiCANet_OPT 曲线整体高于其他方法, 覆盖了更大的召回范围, 进一步印证了其更强的目标检出能力。其中 AP 正是 PR 曲线下的面积, 反映了模型在不同阈值下的平均性能, 较高的 AP 值说明该模型在精确度与召回率之间取得了更好的平衡。

图 8 展示了三个具有代表性的可视化检测案例, 涵盖了鸟类、狗和多人场景, 具有多样的结构、复杂的背景和不同的光照条件, 能够全面验证各模型的泛化能力和鲁棒性。从结果来看,




图 8: 可视化案例对比 (从左到右分别是 Img, Ground Truth, ResNet50, RASNet, RASNet_OPT, PiCANet, PiCANet_OPT, PFANet)

ResNet50 前景形状模糊、目标边界不清晰, 存在明显漏检, 尤其在第二行鸟的下半身和第三行多人背景区域; RASNet 能较好还原目标整体轮廓, 但背景残留多, 狗图中下半部分漏检严重; RASNet_OPT 相较于 RASNet 显著提升, 边缘更锐利、目标更聚焦、背景干扰大幅减少; PiCANet 在细节还原上表现出色, 能捕捉较清晰的边界, 但部分区域 (如第一行狗图) 边缘略显过度平滑; PiCANet_OPT 进一步提升了轮廓保留和背景抑制能力, 前景目标清晰集中, 第二行和第三行的结构还原与 Ground Truth 最为接近, 是各模型中表现最优者。PFANet 的预测结果在形状还原方面表现良好, 目标完整性强, 但边缘细节略逊于 PiCANet 的系列, 背景仍有一定残留, 整体效果介于中游水平。

(三) 消融实验

实验设计. 这里我们为了证明优化确实有效, 设计了完备的消融实验。对于 RASNet, 我们有一部分优化, 一部分是改变了模型架构, 另一部分改变了损失设计, 于是我们分别控制其中一部分不变仅改变另一部分进行消融实验。对于 PiCANet, 我们同样设计了两个优化, 其一是引入了注意力机制层级架构, 其二是嵌入了非局部注意力模块, 我们采用类似 RASNet 的方法进行消融实验。

RASNet 消融实验. 从表 3 可见, 将原始 RASNet 替换为优化结构但保持原始损失 (RASNet_OPT_woLoss) 后, F-measure 从 0.8308 提升至 0.8342, MAE 明显下降至 0.0609, 说明结构优化在提升目标定位和细节还原方面起到了关键作用。反之, 采用新损失但保留原结构 (RASNet_BCE_DICE) 时, F-measure 降为 0.8213, MAE 增加至 0.0725, 性能甚至低于原始 RASNet, 说明单独使用新损失无法充分发挥优势。最终的联合优化版本 (RASNet_OPT) 在 F-measure 上达到 0.8522, 在 AP 上也取得了最优的 0.9337, 表明结构与损失的协同设计能显著提升模型整体性能。图 9 (a) 的 PR 曲线也进一步印证了上述分析, 优化后的模型在不同阈值下均展现出更高的精度和召回率。

图 10 展示了 RASNet 系列模型在消融实验下的可视化效果, 从单物体到多物体场景, 进一步印证了优化策略的有效性。对于单物体案例 (案例一与二中的鸟类): 原始 RASNet 在细节还原方面存在不足, 目标边界模糊, 尤其在鸟喙和尾部等细长结构上不清晰; 优化后的 RASNet_OPT

表 3: 消融实验结果汇总表

Name	F-measure $\uparrow$	MAE $\downarrow$	Average Precision (AP) $\uparrow$	Training Time (s)
ResNet50	0.8264	0.0713	0.9350	240.68
<i>RASNet</i>				
RASNet	0.8308	0.0656	0.9301	254.67
RASNet_BCE_DICE	0.8213	0.0725	0.9231	255.62
RASNet_OPT_woLoss	0.8342	0.0609	0.9407	262.85
RASNet_OPT	0.8522	0.0637	0.9337	267.60
<i>PiCANet</i>				
PiCANet	0.8804	0.0506	0.9554	300.35
PiCANet_Att	0.8878	0.0486	0.9587	306.14
PiCANet_Non_Local	0.8855	0.0491	0.9603	317.89
PiCANet_OPT	0.8935	0.0402	0.9706	320.67




图 9: PR 曲线 (消融实验)

有明显改善, 边缘更锐利, 轮廓贴合度高, 目标结构更加完整; RASNet_BCE_DICE 的预测结果与原始 RASNet 相似, 边缘仍较模糊, 背景也存在一定程度的干扰, 说明仅更换损失函数对边界建模帮助有限。对于多物体场景 (案例三中的多人图像): RASNet 无法准确区分前景与背景, 人物主体轮廓模糊且背景残留严重; RASNet_OPT 在背景抑制上表现显著更好, 前景结构清晰、分割精度高; RASNet_BCE_DICE 效果与原始 RASNet 接近, 背景噪声依然明显。综合来看, 结构优化 (RASNet_OPT_woLoss) 已能带来明显提升, 而结构与损失的协同优化 (RASNet_OPT) 在单物体与复杂场景下均取得了最优表现, 进一步验证了前述定量分析的结论。

PiCANet 消融实验. 从表 3 可见, 在原始 PiCANet 架构中引入注意力机制层级架构 (PiCANet_Att) 与非局部注意力模块 (PiCANet_Non_Local) 均带来了性能提升: 前者使 F-measure 提升至 0.8878, MAE 降至 0.0486, 说明局部注意力机制有助于提升模型对目标边缘的建模能力; 后者则在 AP 上达到 0.9603, 表明长距离依赖信息能有效增强区域内部一致性。进一步地, 联合引入两种优化策略后 (PiCANet_OPT), 模型在各项指标上均取得最优表现, F-measure 达到 0.8935, MAE 降至 0.0402, AP 高达 0.9706, 验证了两种优化方式在目标显著性建模中具有互补性。

图 11 展示了不同版本 PiCANet 模型在三个典型样例中的预测结果。对于单物体场景 (案例




图 10: RASNet 消融实验的可视化案例对比 (从左到右分别是 Img, Ground Truth, ResNet50, RASNet, RASNet_OPT, RASNet_OPT_woLoss, RASNet_BCE_DICE)

一与案例二中的动物和鸟类): 原始 PiCANet 在目标边界处存在轻微模糊, PiCANet_Att 在边缘细节恢复上更清晰, 轮廓更加锐利; PiCANet_Non_Local 则在目标整体结构的一致性上表现更优, 背景噪声更少; PiCANet_OPT 同时具备两者优势, 目标边界清晰、区域完整性高、背景干净, 分割效果最为接近 Ground Truth。对于复杂背景下的多目标场景 (案例三): 原始 PiCANet 出现明显的背景泄露与主体混淆, PiCANet_Att 和 PiCANet_Non_Local 在不同程度上改善了这一问题, 而 PiCANet_OPT 能较好地地区分多个前景人物并显著抑制背景区域, 说明其综合能力更强。

综上, 结构性优化 (注意力层级与非局部模块) 不仅在定量评估中表现优异, 在可视化效果上同样体现出更高的边界敏感性和目标完整性, 进一步验证了优化策略的有效性与互补性。

七、 未来设想与实验心得


通过本次研究与实践, 我们深入复现并分析了三种经典的显著性检测模型, 并围绕结构与损失两个角度开展了多项优化实验。整体流程涵盖了文献阅读、模型实现、训练测试、指标对比与可视化分析, 系统性地提升了我们对显著性检测任务的理解, 也锻炼了我们在模型调试与性能提升方面的工程能力。

尽管目前工作已初步完成, 但仍仅覆盖了该领域的部分方法, 未来仍有较多值得探索的方向。首先, 在模型效率方面, 为了适应移动端或实时推理的需求, 可以考虑引入更轻量化的主干网络, 如 MobileNet [7] 或 ShuffleNet [20], 并结合模型剪枝、量化等压缩技术, 进一步降低计算开销。其次, 可将显著性检测与边缘检测、深度估计等视觉任务进行联合建模, 借助多任务学习提升模型对不同类型信息的感知能力与泛化能力。此外, 在标注数据有限的情形下, 利用伪标签与自监督学习策略也有望进一步挖掘未标注图像的信息潜力, 从而缓解对大规模高质量标注数据的依赖。


最后, 当前模型仍属于“静态预测”范式, 缺乏高层次的推理能力。结合近年来兴起的 Reasoning Models [3, 13, 14, 17], 未来可尝试引入“自我反思”机制, 让模型在生成显著图的过程中进行动态调整与推理判断, 从而提升在复杂场景中的适应能力与表达精度。当然, 这类能力的有



(a) 案例一



(b) 案例二



(c) 案例三

图 11: PiCANet 消融实验的可视化案例对比 (从左到右分别是 Img, Ground Truth, PiCANet, PiCANet_Att, PiCANet_Non_Local, PiCANet_OPT)

效验证也需要构建更具挑战性的数据集与评估体系, 这将是后续可进一步拓展的研究方向。

参考文献

- [1] Ali Borji. What is a salient object? a dataset and a baseline model for salient object detection. *IEEE Transactions on Image Processing*, 2014.
- [2] Ali Borji, Dicky N Sihite, and Laurent Itti. What stands out in a scene? a study of human explicit saliency judgment. *Vision Research*, 2013.
- [3] ByteDance. doubao-1.5-pro. https://seed.bytedance.com/en/special/doubao_1_5_pro, 2025.
- [4] Shuhan Chen, Xiuli Tan, Ben Wang, and Xuelong Hu. Reverse attention for salient object detection. In *ECCV*, 2018.
- [5] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *CVPR*, 2016.
- [6] Xiaojuan Qi Xiaogang Wang Jiaya Jia Hengshuang Zhao, Jianping Shi. Pyramid scene parsing network. *CVPR*, 2017.
- [7] Andrew G Howard, Menglong Zhu, Bo Chen, Dmitry Kalenichenko, Weijun Wang, Tobias Weyand, Marco Andreetto, and Hartwig Adam. Mobilenets: Efficient convolutional neural networks for mobile vision applications. *arXiv preprint arXiv:1704.04861*, 2017.
- [8] Huaizu Jiang, Jingdong Wang, Zejian Yuan, Yang Wu, Nanning Zheng, and Shipeng Li. Salient object detection: A discriminative regional feature integration approach. In *CVPR*, 2013.
- [9] Joon-Young Lee In So Kweon Jongchan Park, Sanghyun Woo. Bam: Bottleneck attention module. *BMVC*, 2018.
- [10] Nian Liu and Junwei Han. A simple pooling-based design for real-time salient object detection. In *CVPR*, 2019.
- [11] Nian Liu, Junwei Han, and Ming-Hsuan Yang. Picanet: Learning pixel-wise contextual attention for saliency detection. In *CVPR*, 2018.
- [12] Nian Liu, Jia Zhang, and Junwei Han. Visual saliency transformer. In *ICCV*, 2021.
- [13] OpenAI. OpenAI o1. <https://openai.com/o1/>, 2024.
- [14] OpenAI. OpenAI o3 and o4-mini System Card. <https://cdn.openai.com/pdf/2221c875-02dc-4789-800b-e7758f3722c1/o3-and-o4-mini-system-card.pdf>, 2025.
- [15] Jianping Shi, Qiong Yan, Li Xu, and Jiaya Jia. Hierarchical image saliency detection on extended cssd. In *TPAMI*, 2015.
- [16] Karen Simonyan and Andrew Zisserman. Very deep convolutional networks for large-scale image recognition. In *ICLR*, 2015.
- [17] R1-V Team. R1-V. <https://github.com/Deep-Agent/R1-V?tab=readme-ov-file>, 2025.

- [18] Francesco Visin, Kyle Kastner, Kyunghyun Cho, Matteo Matteucci, Aaron Courville, and Yoshua Bengio. Renet: A recurrent neural network based alternative to convolutional networks. In *NeurIPS*, 2015.
- [19] Qiong Yan, Li Xu, Jianping Shi, and Jiaya Jia. Hierarchical saliency detection. In *CVPR*, 2013.
- [20] Xiangyu Zhang, Xinyu Zhou, Mengxiao Lin, and Jian Sun. Shufflenet: An extremely efficient convolutional neural network for mobile devices. In *CVPR*, 2018.
- [21] Yujie Zhang, Zhe Lin, Hairong Chen, Yutong Liu, and Weisheng Dong. Salient object detection via integrity learning. *arXiv preprint arXiv:2101.07663*, 2021.
- [22] Shuhan Zhao, Huchuan Liu, Jian Zhu, and Yutong Zhang. Pyramid feature attention network for saliency detection. In *CVPR*, 2019.

MINIB