

基于权重重要性分级放大的统一精度量化方法：面向大语言模型高效部署-Project Proposal

Si-Cheng Feng¹ Yipeng Du¹

¹ Nankai University

摘要

大语言模型 (LLMs) 在多种自然语言处理任务 (e.g., 机器翻译, 情感分析, 阅读理解, 对话系统, 问答系统) 中取得了显著进展。在实际应用中, 尤其是在资源有限的情况下 (如边缘设备等), 其庞大的模型规模和高昂的计算成本带来了挑战。本地运行 LLM 不仅能降低云计算成本, 还能保护用户隐私。为了解决上述问题, 量化 (Quantization) 是减少模型内存占用和加速推理的重要方法, 但传统量化方法可能因量化误差导致性能下降, 限制了大模型的直接部署。近年来, 针对 LLM 的量化方法取得了显著进展, 尤其是在保护模型性能的同时显著降低硬件资源需求方面。本文对于 LLM 量化进行了分析, 并对现有方法的挑战与未来研究方向进行探讨, 提出了一种基于权重重要性分级放大的统一精度量化方法: 该方法通过结合权重的 L1 范数分析和多级动态缩放策略, 在保持模型性能的同时实现高效的硬件推理支持。在之后的期末项目里, 我们会参照此 Proposal, 立志于完成一项扎实的工作。

1. 准备工作

1.1. 小组成员信息

1. Sicheng Feng (冯思程): 学号 2112213, 邮箱 fsc-nkuucs@gmail.com
2. Yipeng Du (杜旖苒): 学号 2113958, 邮箱 nat-sunoshion@gmail.com

1.2. 实验环境准备

小组成员分别有服务器可以访问并可以用于本项目, 涉及的服务器配置如下:

1. 8 * RTX 4090, 双路 Intel Xeon Gold 6430, 64 核心, 128 线程。
2. 8 * V100, 双路 Intel Xeon Silver 4214R, 24 核心, 48 线程。

2. 问题定义

大语言模型 (LLMs) 在多种自然语言处理任务中取得了突破性进展, 例如机器翻译 [24, 7]、情感分析 [4]、阅读理解、对话系统 [23] 和问答系统 [1], 基本架构是 Transformer [18]。然而, LLMs 的出色表现背后是庞大的参数量和高计算需求, 这带来了实际应用中的种种挑战, 尤其在资源受限的环境下 (如边缘设备等)。例如, 许多先进的 LLMs 模型需要数百 GB 的存储空间和大量的 GPU 计算资源 (e.g., GPT-175B [1] 拥有 1750 亿个参数, 在半精度 (FP16) 格式下至少需要 350GB 的内存, 并且推理需要至少五张 80GB 内存的 A100 GPU。), 这使得它们在部署时面临巨大的硬件成本和能耗问题。因此, 如何在不显著降低模型性能的情况下降低其计算和存储开销成为了亟待解决的课题。

为应对这些挑战, 模型压缩技术 [9] 逐渐成为优化 LLMs 的关键手段。模型压缩通过将大型、高资源需求的模型转化为适合资源有限环境的紧凑版本, 从而提升模型的推理速度并减少资源消耗。本文从四个核心技术角度探讨了 LLMs 的模型压缩, 包括

量化、剪枝、知识蒸馏和低秩分解。量化技术通过将模型参数表示为更低精度的数据类型来减少模型大小和计算需求 [12]；剪枝方法则通过去除冗余参数来简化模型结构 [15]；知识蒸馏则是利用一个预训练的大模型（教师模型）来指导较小的模型（学生模型）学习，从而在小模型中保留原始大模型的部分能力 [10]；而低秩分解方法则将权重矩阵分解为更小的矩阵，进一步降低了计算复杂度 [17]。这些技术的相结合在一定程度上缓解了 LLMs 在实际应用中的部署难题。

本项目在以量化为主要研究方向，研究量化技术，旨在能够通用性地减少大型语言模型对计算资源的需求，让大模型有机会在资源限制的系统上运行。

3. 国内外研究现状

量化 [8] 是一种减少模型参数位数（即精度）的技术，以降低存储和计算成本，同时尽可能保持模型性能。量化可分为量化感知训练（QAT）和训练后量化（PTQ）。QAT 需要对模型进行再训练以校正因量化带来的误差，而 PTQ 则直接在推理阶段应用量化模型。

3.1. 量化感知训练（QAT）

QAT 通过再训练提升模型性能，减少量化带来的精度损失。例如，LLM-QAT [13] 使用自我蒸馏生成数据进行训练，BitDistiller [5] 结合自蒸馏，优化至低于 4 位的量化效果，而 OneBit 提出 1 位参数量化方法，实现极低位数的量化部署。QAT 可以有效减少精度损失，但由于 LLM 参数量巨大，再训练开销高。为此，结合参数高效微调（PEFT）的方法，如 QLoRA 等，可以提高 QAT 效率，但这些方法多依赖特定任务。

3.2. 训练后量化（PTQ）

PTQ 在不需要再训练的情况下，将全精度模型转换为低精度版本。PTQ 主要分为**权重量化**、**权重-激活量化**和**KV 缓存量化**。权重量化仅对权重进行量化，而权重-激活量化则扩展至激活值。研究表明，

激活量化对权重量化更敏感，因此权重量化可以在更低的位宽下实现。KV 缓存量化则针对 KV 缓存（用于存储注意力层的键和值）进行量化，减少内存占用并提升长序列处理的效率。

权重量化。权重量化是一种传统且广泛应用的方法。例如，LUT-GEMM [16] 使用二进制编码实现矩阵乘法加速，GPTQ [6] 采用基于逆 Hessian 信息的层级量化方法，QuIP [2] 利用 Hessian 矩阵的 LDL 分解进行 2 位量化。为了进一步减少量化误差，一些方法会保留敏感权重的高精度表示，例如 AWQ [12] 存储最重要的 1% 权重，以优化量化效果。

权重-激活量化。许多研究致力于权重-激活量化，其中 ZeroQuant [20] 首先实现了 LLM 的权重-激活量化。为处理激活值中的异常值，LLM.int8() [3] 专门保留了这些异常值的高精度。SmoothQuant [19] 设计了通道级的平滑变换，减少了激活值中的异常波动。其他方法如 RPTQ [21] 也采用了各种方式处理通道间的数值差异或异常值，以改善量化效果。

KV 缓存量化。随着 LLM 输入长度的增加，KV 缓存的内存需求也随之增长。KVQuant [11] 等方法提出了通道级和非均匀量化技术，以提升长序列推理的效率。KIVI [14] 则通过分析 KV 缓存中的元素分布，发现可以分别对键缓存和值缓存采用不同的量化策略，成功将 KV 缓存量化到 2 位。WKVQuant [22] 采用二维量化策略管理 KV 缓存，实现了接近权重-激活量化的内存节省效果。

4. 计划复现论文理解阐述

这里，我们列举了可能复现的四篇论文，届时会视情况选择其中三篇进行复现。

AWQ [12]。LLMs 的设备端部署（on-device LLM）在降低云计算成本和保护用户隐私方面具有重要意义。然而，模型规模庞大和硬件资源有限性带来了巨大挑战。论文提出了一种硬件友好的低比特权重量化方法——激活感知权重量化（Activation-aware




图 1. AWQ [12] 示意图。根据激活分布（中间），我们可以在 LLM 中找到 1% 的突出权重。将突出权重保留在 FP16 中可以显著提高量化性能（PPL 从 43.2（左图）降至 13.0（中图）），但混合精度格式不具备硬件效率。AWQ（右图）对每个通道进行缩放，以保护突出权重并减少量化误差。




图 2. SmoothQuant [19] 的直觉是：激活 X 很难量化，因为异常值会拉大量化范围，使大部分值的有效比特数很少。我们在离线过程中将比例方差从激活值迁移到权重 W ，以降低激活值的量化难度。平滑后的激活值 $\hat{X}$ 和调整后的权重 $\hat{W}$ 都很容易量化。

Weight Quantization, AWQ)。AWQ 发现，仅保护 1% 的关键权重即可显著降低量化误差，这些权重的选择需参考激活分布而非权重本身。

为了避免混合精度量化的硬件低效问题，AWQ 通过数学推导证明，放大关键权重通道的比例可以减少量化误差，并通过等效变换保护关键通道，比例因子则基于离线激活统计确定。无需反向传播或重构，AWQ 能够很好地泛化到不同领域和模态，避免过拟合。

AWQ 在语言建模、指令调优和多模态任务上均表现优异，是首次在多模态模型上取得如此出色的量化效果。同时，论文还实现了高效的推理框架 TinyChat，通过内核融合和权重优化，在桌面和移动 GPU 上比 Huggingface FP16 实现提速 3 倍以上，并成功将 70B Llama-2 模型部署至移动 GPU。

SmoothQuant [19]. LLMs 尽管性能优异，但对计算和内存资源要求极高。量化可以减少内存使用并加速推理，但现有方法难以同时兼顾精度和硬件效

率。论文提出了 SmoothQuant，一种无需训练、精度友好且通用的 PTQ 方法，可实现 LLM 的 8 比特权重和 8 比特激活（W8A8）量化。

基于权重易于量化而激活较难的特点，SmoothQuant 通过数学等效变换，离线地将量化难度从激活迁移至权重，从而平滑激活的离群值。这一方法支持所有矩阵乘法运算的 INT8 量化，适用于包括 OPT、BLOOM、GLM、MT-NLG、Llama-1/2、Falcon、Mistral 和 Mixtral 在内的多种模型。

实验表明，SmoothQuant 在几乎无损精度的情况下，实现了最高 1.56 倍的推理速度提升和 2 倍的内存占用减少，使得单节点上服务 530B 参数模型成为可能。该方法为 LLM 的硬件成本优化提供了开箱即用的解决方案，加速了 LLM 的普及与应用。

BitDistiller [5]. LLMs 的扩展在自然语言处理领域取得了显著进展，但也带来了部署上的重大挑战。权重量化成为降低内存和计算需求的主流解决方案。论文提出了 BitDistiller 框架，将量化感知训练 QAT




图 3. 描述 BitDistiller [5] 基于 QAT 的 KD 框架。

与知识蒸馏 KD 相结合，以提升 LLM 在超低精度（低于 4 比特）下的性能。

具体而言，BitDistiller 首先采用定制的不对称量化与裁剪技术，最大限度地保留量化权重的精度。随后引入了一种新颖的置信感知 Kullback-Leibler 散度（Confidence-Aware Kullback-Leibler Divergence, CAKLD）目标函数，通过自蒸馏方式加速收敛并提升模型性能。实验证明，BitDistiller 在 3 比特和 2 比特配置下，在通用语言理解和复杂推理基准上均显著优于现有方法。此外，BitDistiller 成本更低，对数据和训练资源的需求更少。

LLM.int8() [3]. LLMs 被广泛应用，但推理过程对 GPU 内存需求极大。论文提出了一种用于 Transformer 模型中前馈层和注意力投影层的 Int8 矩阵乘法方法，可以将推理所需内存减半，同时保持全精度性能。

通过该方法，可直接加载 175B 参数的 16/32 位模型检查点，转换为 Int8 格式后立即使用，且无性能损失。这得益于对 Transformer 语言模型中高度系统化的显著特征的理解和处理，这些特征主导了注意力机制和预测性能。为应对这些特征，论文开发了一种两阶段量化方法——LLM.int8()。第一阶段使用向量级量化，为矩阵乘法中的每个内积分配独立的归一化常数，以量化大多数特征；第二阶段对突出的离群特征维度采用混合精度分解方案，将其隔离至 16 位矩阵乘法中，而 99.9% 以上的值仍

通过 8 位运算处理。

实验证明，使用 LLM.int8() 可以在不损失性能的情况下推理最多 175B 参数的 LLM。这一成果显著提升了模型的可访问性，例如支持在单台消费级 GPU 服务器上运行 OPT-175B 或 BLOOM 模型。

5. 创新想法 & 技术路线描述

这里我们尝试提出一种基于权重重要性分级放大的统一精度量化方法。该方法通过结合权重的 L1 范数分析和多级动态缩放策略，在保持模型性能的同时实现高效的硬件推理支持。主要创新点如下：

首先，我们对模型的权重进行重要性分析，采用 L1 范数作为衡量标准，将权重分为不同重要性梯度。重要性高的权重通常对模型性能贡献较大，因此需要更高的保护。而低重要性的权重可以使用较低精度表示，从而达到压缩模型的目的。其次，为了解决硬件对统一量化精度的需求，我们对高重要性权重采用动态缩放策略，将其数值范围放大到更适合低比特量化的范围。通过这种数学等效变换，可以减少量化误差的影响，同时保证计算的一致性。在推理阶段，我们通过对激活值进行分组反缩放，确保量化后的模型与原始模型在数学上等价，既简化了实现复杂度，也保证了模型的推理效率。

技术路线分为三个关键步骤：第一步，计算权重的 L1 范数并进行重要性排序，根据预设的分位点将权重划分为高、中、低三个梯度（或者更多梯度，甚至可以尝试自适应选取梯度数）。第二步，对不同重要性梯度的权重分别应用不同的缩放因子，放大高重要性权重的数值范围以适配低比特量化，并对权重矩阵进行统一的低比特量化表示（如 INT8）。第三步，在推理过程中，动态调整激活值以匹配权重的缩放因子，从而实现与原始模型的数学一致性。

此方法的优势在于，通过对权重重要性分级和动态缩放的结合，能够有效保护关键权重，显著降低量化误差，同时以统一的低比特精度表示所有权重，兼顾模型压缩效率和硬件友好性。此外，整个流程无需重新训练模型，仅需小量的校准数据即可完成，从而具备良好的通用性和实际应用价值。




图 4. LLM.int8() [3] 的示意图。在给定 16 位浮点输入 X_{f16} 和权重 W_{f16} 的情况下，特征和权重被分解成大振幅特征子矩阵和其他值。离群特征矩阵以 16 位乘法运算。所有其他值以 8 位乘法运算。我们通过 C_x 和 C_w 的绝对最大值按行和列进行缩放，执行 8 位矢量乘法，然后将输出量化为 Int8。Int32 矩阵乘法输出 Out_{i32} 通过归一化常数 $C_x C_w$ 的外积进行去量化。最后，离群值和正则输出都被累加为 16 位浮点输出。

6. 总结

本项目围绕大语言模型（LLMs）的量化问题，提出了一种基于权重重要性分级放大的统一精度量化方法，旨在解决当前模型量化过程中性能损失和硬件效率的平衡问题。通过结合权重的 L1 范数分析和多级动态缩放策略，该方法在降低模型存储和计算成本的同时，保持了模型的性能，适配了硬件的统一精度需求。

本方法的潜在优势在于，不仅实现了统一的低比特精度量化，降低了硬件部署的复杂性，还无需重新训练，仅需少量校准数据即可完成量化处理，具备高效性和广泛的适用性。未来，我们计划在多个主流语言模型（如 GPT、Llama、OPT）上验证方法的有效性，并探索更多的实际应用场景（如边缘设备部署）。

本项目尝试为高效的大语言模型量化提供一种新思路，为资源受限环境下的大模型推理提供技术支持。同时，我们希望通过本项目的研究，为进一步优化大语言模型的部署与应用打下坚实基础。

参考文献

- [1] T. B. Brown. Language models are few-shot learners. arXiv preprint arXiv:2005.14165, 2020. 1
- [2] J. Chee, Y. Cai, V. Kuleshov, and C. M. De Sa. Quip: 2-bit quantization of large language models with guarantees. In NeurIPS, 2024. 2
- [3] T. Dettmers, M. Lewis, Y. Belkada, and L. Zettlemoyer. Gpt3. int8 (): 8-bit matrix multiplication for transformers at scale. In NeurIPS, 2022. 2, 4, 5
- [4] J. Devlin. Bert: Pre-training of deep bidirectional transformers for language understanding. arXiv preprint arXiv:1810.04805, 2018. 1
- [5] D. Du, Y. Zhang, S. Cao, J. Guo, T. Cao, X. Chu, and N. Xu. Bitdistiller: Unleashing the potential of sub-4-bit llms via self-distillation. arXiv preprint arXiv:2402.10631, 2024. 2, 3, 4
- [6] E. Frantar, S. Ashkboos, T. Hoefer, and D. Alistarh. Optq: Accurate quantization for generative pre-trained transformers. In ICLR, 2022. 2
- [7] X. Garcia, Y. Bansal, C. Cherry, G. Foster, M. Krikun, M. Johnson, and O. Firat. The unreasonable effectiveness of few-shot learning for machine translation. In ICML. PMLR. 1
- [8] R. M. Gray and D. L. Neuhoff. Quantization. IEEE transactions on information theory, 44(6):2325–2383, 1998. 2
- [9] S. Han, H. Mao, and W. J. Dally. Deep compression: Compressing deep neural networks with pruning, trained quantization and huffman coding. In ICLR, 2016. 1
- [10] G. Hinton, O. Vinyals, and J. Dean. Distilling the knowledge in a neural network. In NeurIPS Workshop, 2014. 2
- [11] C. Hooper, S. Kim, H. Mohammadzadeh, M. W. Mahoney, Y. S. Shao, K. Keutzer, and A. Gholami. Kvquant: Towards 10 million context length llm inference with kv cache quantization. arXiv preprint arXiv:2401.18079, 2024. 2
- [12] J. Lin, J. Tang, H. Tang, S. Yang, W.-M. Chen, W.-C. Wang, G. Xiao, X. Dang, C. Gan, and S. Han. Awq: Activation-aware weight quantization for on-device llm compression and acceleration. In MLSys, 2024. 2, 3
- [13] Z. Liu, B. Oguz, C. Zhao, E. Chang, P. Stock, Y. Mehdad, Y. Shi, R. Krishnamoorthi, and V. Chandra. Llm-qat: Data-free quantization aware training for large language models. arXiv preprint arXiv:2305.17888, 2023. 2
- [14] Z. Liu, J. Yuan, H. Jin, S. Zhong, Z. Xu, V. Braverman, B. Chen, and X. Hu. Kivi: A tuning-free asymmetric 2bit quantization for kv cache. arXiv preprint arXiv:2402.02750, 2024. 2
- [15] X. Ma, G. Fang, and X. Wang. Llm-pruner: On the structural pruning of large language models. In NeurIPS, 2023. 2
- [16] G. Park, B. Park, M. Kim, S. Lee, J. Kim, B. Kwon, S. J. Kwon, B. Kim, Y. Lee, and D. Lee. Lut-gemm: Quantized matrix multiplication based on luts for efficient inference in large-scale generative language models. arXiv preprint arXiv:2206.09557, 2022. 2
- [17] R. Saha, V. Srivastava, and M. Pilanci. Matrix compression via randomized low rank and low precision factorization. In NeurIPS, 2023. 2
- [18] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin. Attention is all you need. In NeurIPS, 2017. 1
- [19] G. Xiao, J. Lin, M. Seznec, H. Wu, J. Demouth, and S. Han. Smoothquant: Accurate and efficient post-training quantization for large language models. In ICML, 2023. 2, 3
- [20] Z. Yao, R. Yazdani Aminabadi, M. Zhang, X. Wu, C. Li, and Y. He. Zeroquant: Efficient and affordable post-training quantization for large-scale transformers. In NeurIPS, 2022. 2
- [21] Z. Yuan, L. Niu, J. Liu, W. Liu, X. Wang, Y. Shang, G. Sun, Q. Wu, J. Wu, and B. Wu. Rptq: Reorder-based post-training quantization for large language models. arXiv preprint arXiv:2304.01089, 2023. 2
- [22] Y. Yue, Z. Yuan, H. Duanmu, S. Zhou, J. Wu, and L. Nie. Wkvquant: Quantizing weight and key/value cache for large language models gains more. arXiv preprint arXiv:2402.12065, 2024. 2
- [23] Y. Zhang. Dialogpt: Large-scale generative pre-training for conversational response generation. arXiv preprint arXiv:1911.00536, 2019. 1
- [24] W. Zhu, H. Liu, Q. Dong, J. Xu, S. Huang, L. Kong, J. Chen, and L. Li. Multilingual machine translation with large language models: Empirical results and analysis. arXiv preprint arXiv:2304.04675, 2023. 1