

# 自然语言处理-实验一

Si-Cheng Feng<sup>1</sup>

<sup>1</sup> Nankai University

## 摘要

大语言模型 (LLMs) 在多种自然语言处理任务 (e.g., 机器翻译, 情感分析, 阅读理解, 对话系统, 问答系统) 中取得了显著进展。在实际应用中, 尤其是在资源有限的情况下, 其庞大的模型规模和高昂的计算成本带来了挑战。为了解决这些问题, 模型压缩成为了一个重要的研究方向。本文系统综述了针对大语言模型的模型压缩技术, 涵盖了量化、剪枝、知识蒸馏和低秩分解等方法, 首先, 我们介绍参数剪枝和量化的方法, 随后介绍其他技术。对于每个类别, 我们都提供了关于性能、相关应用、优缺点的分析, 并重点展示了近来的技术进展。然后, 我们总结了评估指标、用于模型性能评估的主要数据集以及最新的基准测试。最后, 我们对本文进行了总结, 讨论了尚存的挑战以及未来可能的研究方向。本综述为提高 LLM 的效率和实用性提供了有价值的参考, 并为未来的研究工作铺设了基础。

## 1. 介绍

大语言模型 (LLMs) 在多种自然语言处理任务中取得了突破性进展, 例如机器翻译 [46, 9]、情感分析 [4]、阅读理解、对话系统 [43] 和问答系统 [1], 基本架构是 Transformer [33]。然而, LLMs 的出色表现背后是庞大的参数量和计算需求, 这带来了实际应用中的种种挑战, 尤其在资源受限的环境下。例如, 许多先进的 LLMs 模型需要数百 GB 的存储空间和大量的 GPU 计算资源 (e.g., GPT-175B [1] 拥有 1750 亿个参数, 在半精度 (FP16) 格式下至少需要 350GB 的内存, 并且推理需要至少五张 80GB

内存的 A100 GPU。), 这使得它们在部署时面临巨大的硬件成本和能耗问题。因此, 如何在不显著降低模型性能的情况下降低其计算和存储开销成为了亟待解决的课题。

为应对这些挑战, 模型压缩技术 [11] 逐渐成为优化 LLMs 的关键手段。模型压缩通过将大型、高资源需求的模型转化为适合资源有限环境的紧凑版本, 从而提升模型的推理速度并减少资源消耗。本文从四个核心技术角度探讨了 LLMs 的模型压缩, 包括量化、剪枝、知识蒸馏和低秩分解。量化技术通过将模型参数表示为更低精度的数据类型来减少模型大小和计算需求 [17]; 剪枝方法则通过去除冗余参数来简化模型结构 [20]; 知识蒸馏则是利用一个预训练的大模型 (教师模型) 来指导较小的模型 (学生模型) 学习, 从而在小模型中保留原始大模型的部分能力 [12]; 而低秩分解方法则将权重矩阵分解为更小的矩阵, 进一步降低了计算复杂度 [27]。这些技术的相结合在一定程度上缓解了 LLMs 在实际应用中的部署难题。

本综述旨在对上述模型压缩技术进行系统回顾, 并对每种技术的性能、应用场景、优势与不足进行深入分析。此外, 我们还讨论了用于模型评估的指标、常用数据集 [22, 26] 和最新的基准测试工作。如果你想进一步探索, 这里有一些可以提供帮助的 surveys [47, 44]。

## 2. 量化

量化 [10] 是一种减少模型参数位数 (即精度) 的技术, 以降低存储和计算成本, 同时尽可能保持模

---

<sup>1</sup> 参考 [47]




图 1. 大型语言模型的模型压缩方法的分类<sup>1</sup>。

型性能。量化可分为量化感知训练（QAT）和训练后量化（PTQ）。QAT 需要对模型进行再训练以校正因量化带来的误差，而 PTQ 则直接在推理阶段应用量化模型。

## 2.1. 量化感知训练（QAT）

QAT 通过再训练提升模型性能，减少量化带来的精度损失。例如，LLM-QAT [18] 使用自我蒸馏生成数据进行训练，BitDistiller [5] 结合自蒸馏，优化至低于 4 位的量化效果，而 OneBit 提出 1 位参数量化方法，实现极低位数的量化部署。QAT 可以有效减少精度损失，但由于 LLM 参数量巨大，再训练开销高。为此，结合参数高效微调（PEFT）的方法，如 QLORA 等，可以提高 QAT 效率，但这些方法多依赖特定任务。

## 2.2. 训练后量化（PTQ）

PTQ 在不需要再训练的情况下，将全精度模型转换为低精度版本。PTQ 主要分为**权重量化**、**权重-激活量化**和**KV 缓存量化**。权重量化仅对权重进行量化，而权重-激活量化则扩展至激活值。研究表明，

激活量化对权重量化更敏感，因此权重量化可以在更低的位宽下实现。KV 缓存量化则针对 KV 缓存（用于存储注意力层的键和值）进行量化，减少内存占用并提升长序列处理的效率。

**权重量化。**权重量化是一种传统且广泛应用的方法。例如，LUT-GEMM [25] 使用二进制编码实现矩阵乘法加速，GPTQ [7] 采用基于逆 Hessian 信息的层级量化方法，QuIP [2] 利用 Hessian 矩阵的 LDL 分解进行 2 位量化。为了进一步减少量化误差，一些方法会保留敏感权重的高精度表示，例如 AWQ [17] 存储最重要的 1% 权重，以优化量化效果。

**权重-激活量化。**许多研究致力于权重-激活量化，其中 ZeroQuant [39] 首先实现了 LLM 的权重-激活量化。为处理激活值中的异常值，LLM.int8() 专门保留了这些异常值的高精度。SmoothQuant [38] 设计了通道级的平滑变换，减少了激活值中的异常波动。其他方法如 RPTQ [40] 也采用了各种方式处理通道间的数值差异或异常值，以改善量化效果。

**KV 缓存量化。**随着 LLM 输入长度的增加，KV 缓存的内存需求也随之增长。KVQuant [13] 等方法

提出了通道级和非均匀量化技术，以提升长序列推理的效率。KIVI [19] 则通过分析 KV 缓存中的元素分布，发现可以分别对键缓存和值缓存采用不同的量化策略，成功将 KV 缓存量化到 2 位。WKVQuant [42] 采用二维量化策略管理 KV 缓存，实现了接近权重-激活量化的内存节省效果。

### 3. 剪枝

剪枝 [15] 是一种通过移除冗余部分来减少模型规模或复杂度的技术，主要分为无结构剪枝、结构化剪枝和半结构化剪枝。无结构剪枝对单个参数进行稀疏化处理，但生成的模型结构不规则，需要特殊优化才能加速推理。结构化剪枝则移除整个神经元、注意力头或层等较大组件，保留了网络的整体结构，更适合硬件加速。半结构化剪枝介于两者之间，可以同时实现细粒度剪枝和结构化正则化，例如 N:M 稀疏性，通过保留每 M 个参数中的 N 个非零元素实现稀疏化。

#### 3.1. 无结构剪枝

无结构剪枝通常不需要再训练来恢复性能，但会导致不规则结构。SparseGPT [6] 在无需再训练的情况下实现了单次剪枝，将稀疏性提升至 50% 以上，且性能损失很小。Wanda [31] 通过选择最小的权重乘以输入激活的范数实现稀疏性，而不需要再训练或权重更新。Flash-LLM [36] 则提供了在 GPU 上加速无结构剪枝的硬件支持。

#### 3.2. 结构化剪枝

结构化剪枝有助于在传统硬件上加速推理，但需要细致的微调以恢复性能。LLM-Pruner [20] 基于梯度信息进行一键式剪枝，Shortened LLaMA [14] 则通过选择不重要的 Transformer 块来实现深度剪枝。Sheared LLaMA [37] 通过正则化直接在模型形状上施加约束，以优化剪枝过程。

#### 3.3. 半结构化剪枝

半结构化剪枝可以在一定模式下剪除部分权重，以兼顾细粒度剪枝和硬件兼容性。E-Sparse [16] 通

<sup>3</sup>参考 [47]

过信息熵评估参数重要性，并采用全局和局部混洗技术优化信息分布。SparseGPT 和 Wanda 也探索了 N:M 稀疏性剪枝，分别通过分块和计算重要性分数来选择被保留的权重。目标硬件的兼容性对选择最佳剪枝策略尤为重要，例如 Ampere GPU 架构支持 2:4 的细粒度稀疏性，可用于加速稀疏神经网络。

**动态剪枝与校准数据集。**动态剪枝方法可以根据当前任务的需求剪除模型的不同部分，以提高特定任务的性能。此外，为 PTQ 和剪枝方法准备高质量的校准数据集至关重要，能够显著提升压缩模型的准确性和下游任务表现，因此需要精心选择和准备高质量的校准数据。

### 4. 知识蒸馏

知识蒸馏 [12] 是一种将大型复杂模型（教师模型）的知识迁移到较小模型（学生模型）的技术，分为黑盒蒸馏和白盒蒸馏两类。

#### 4.1. 黑盒蒸馏

黑盒蒸馏只使用教师模型的输出，通常用于闭源模型，如 GPT-4 等大型语言模型 (LLM)。通过让教师模型生成蒸馏数据集，用于微调学生模型，能够传递任务能力。黑盒蒸馏中还包含链式思维 (CoT) 蒸馏 [35]、上下文学习蒸馏和指令跟随蒸馏等方法，增强学生模型在推理和指令处理方面的能力。

**链式思维蒸馏。**链式思维蒸馏通过教师模型生成中间推理步骤，提升学生模型的复杂任务处理能力。研究表明，通过这种逐步推理过程，学生模型能够更好地理解和解释问题，尤其在推理能力的提升方面显著。此外，问题分解方法还将复杂问题分解为子问题，使学生模型逐步解决。

**上下文学习蒸馏。**上下文学习蒸馏利用结构化提示和示例让学生模型在不同任务上生成合理响应。通过模仿教师模型的软标签和实际标签，学生模型能够在各种任务上更好地泛化，有助于提高模型的零样本学习能力。

**指令跟随蒸馏。**指令跟随蒸馏通过指令提示，让学生模型学习教师模型处理指令的能力。一些方法如 SELF-INSTRUCT [34] 使用学生模型作为教师生




图 2. LLM 模型压缩方法的示意。在众多模型压缩技术中，量化感知训练（QAT）和知识蒸馏（KD）是面向特定任务的压缩方法，能够根据任务需求进行优化。相对而言，其他压缩方法则为任务无关型，设计上不依赖特定任务，可适用于不同场景下的通用压缩<sup>3</sup>。

成指令数据，进一步微调学生模型，使其在指令处理上更具适应性。

#### 4.2. 白盒蒸馏

白盒蒸馏允许学生模型深入理解教师模型的内部结构，获得更高的性能。例如，MINILLM 使用逆向 KL 散度来防止学生模型过度估计低概率区域，并通过逐层对齐隐藏表示，缩小学生与教师模型的知识差距。虽然白盒蒸馏能深层次地学习教师模型的知识，但开源 LLM 的性能通常不及闭源 LLM，因此可通过先进行黑盒蒸馏，再通过开源模型执行白盒蒸馏来进一步优化学生模型的表现。

### 5. 低秩分解

低秩分解 [29] 通过将大型矩阵分解为更小的矩阵，以减少空间占用和计算量。例如，将大矩阵  $W$  分解为两个小矩阵  $U$  和  $V$ ，即  $W \approx UV$ ，其中  $U$  和  $V$  的维度远小于原始矩阵。近期研究成功地将低秩分解应用于大语言模型的压缩中。例如，LPLR [27]

方法利用随机低秩和低精度分解压缩权重矩阵，减少存储和计算开销；ASVD [41] 则通过权重矩阵的对角缩放和层级调整的奇异值分布来优化压缩效果，从而最小化模型性能的损失。此外，LASER [28] 方法选择性地对特定层的高阶权重矩阵进行降秩，提升了模型在处理稀有数据和抵抗问题改写上的表现。

## 6. 指标 & 基准测试

### 6.1. 指标

模型压缩的效果可以通过多个指标来衡量，这些指标评估了压缩后模型在计算效率、存储需求以及实际应用中的表现。

- **模型大小：**通常通过模型的参数总数来衡量，参数越多，所需计算资源和内存越大。
- **浮点运算次数：**表示模型执行一次推理所需的浮点运算量，FLOPs 越少，模型运行速度越快，效率越高。
- **平均 FLOPs 利用率：**量化模型实际使用的

FLOPs 与设备最大 FLOPs 的比值，反映计算资源的实际使用效率。

- **推理时间**：模型处理输入并生成响应所需的时间，尤其对于实时响应的应用场景至关重要。
- **加速比**：压缩后模型与原模型推理时间的比值，表示压缩后速度的提升效果。
- **压缩比**：原始模型大小与压缩后模型大小的比值，压缩比越高，表示模型的内存和存储需求降低得越多。

## 6.2. 基准测试

这些数据集和基准测试主要用于评估压缩后的大语言模型 (LLMs) 在不同任务上的表现：

- WikiText-2, C4 和 PTB [21, 22, 26]：用于评估语言模型的困惑度 (perplexity)，这是衡量模型语言生成质量的重要指标。
- LAMBADA, PIQA 和 OpenBookQA [24, 23]：用于评估模型的零样本能力，即在没有特定训练的情况下完成新任务的能力。
- GSM8K, CommonsenseQA 和 StrategyQA [3, 32]：用于评估模型的推理能力，测试模型在常识和逻辑推理方面的表现。
- BIG-Bench (BBH) [30]：涵盖 200 多个 NLP 任务，包括文本理解、推理和数学推理等，旨在多维度上评估 LLMs 的性能。
- Unseen Instructions Datasets [45, 34]：如 Vicuna-Instructions 和 User-Oriented-Instructions，用于测试模型在面对未知任务时的表现，检查模型如何处理从未见过的指令。
- EleutherAI LM Harness [8]：一个统一的评估框架，支持超过 60 个标准学术基准测试及其变体，确保评估的可重复性和公平性。

## 7. 挑战 & 未来方向

在 LLM 模型压缩的研究中，仍存在诸多挑战和未来发展的方向：

**压缩 LLM 的推理效率与部署优化**。在实际部署中，压缩模型的效率是关键因素。可以通过计算密集度、内存占用和吞吐量等指标评估模型，还可

以利用 Roofline 模型来分析压缩 LLM 在特定硬件上的资源效率，从而指导模型在实际硬件中的优化，这部分硬件相关性较大，需要较强的硬件基础。

**压缩与模型规模定律的关系**。模型规模定律指出模型大小、数据集规模和计算资源对性能有显著影响。在压缩 LLM 的过程中，如何平衡模型大小与性能的关系是一个根本性问题，需要深入研究规模定律的机理，以期在压缩中更好地掌握性能与尺寸的平衡。

**自动化压缩技术的探索**。现有的压缩方法多依赖于手动设计，如知识蒸馏的学生模型架构设计。未来可以结合 AutoML 技术（如元学习和神经架构搜索），使得压缩过程更加自动化，从而减少人为干预，降低成本，并根据具体任务需求自动优化压缩策略。

**模型压缩的可解释性**。模型压缩后，理解和解释压缩对模型的影响至关重要。增强模型压缩方法的可解释性，不仅有助于分析压缩过程中的变化和取舍，也有助于确保压缩模型在实际应用中满足性能需求，并提升其效率和准确性。

## 8. 结论

本文综述了大语言模型的模型压缩技术，涵盖了压缩方法、评估指标和基准数据集等内容。在探讨 LLM 压缩技术的过程中，我们揭示了其中的挑战和机遇。我们希望本综述能为相关领域的研究人员提供有价值的参考，助力对这一重要课题的进一步探索。

## 参考文献

- [1] T. B. Brown. Language models are few-shot learners. arXiv preprint arXiv:2005.14165, 2020. 1
- [2] J. Chee, Y. Cai, V. Kuleshov, and C. M. De Sa. Quip: 2-bit quantization of large language models with guarantees. In NeurIPS, 2024. 2
- [3] K. Cobbe, V. Kosaraju, M. Bavarian, M. Chen, H. Jun, L. Kaiser, M. Plappert, J. Tworek, J. Hilton, R. Nakano, et al. Training verifiers to solve math word problems. arXiv preprint arXiv:2110.14168, 2021. 5
- [4] J. Devlin. Bert: Pre-training of deep bidirectional transformers for language understanding. arXiv preprint arXiv:1810.04805, 2018. 1

- [5] D. Du, Y. Zhang, S. Cao, J. Guo, T. Cao, X. Chu, and N. Xu. Bitdistiller: Unleashing the potential of sub-4-bit llms via self-distillation. arXiv preprint arXiv:2402.10631, 2024. 2
- [6] E. Frantar and D. Alistarh. Sparsegpt: Massive language models can be accurately pruned in one-shot. In ICML, 2023. 3
- [7] E. Frantar, S. Ashkboos, T. Hoefer, and D. Alistarh. Optq: Accurate quantization for generative pre-trained transformers. In ICLR, 2022. 2
- [8] L. Gao, J. Tow, S. Biderman, S. Black, A. DiPofi, C. Foster, L. Golding, J. Hsu, K. McDonell, N. Muenighoff, et al. A framework for few-shot language model evaluation. Version v0. 0.1. Sept, 10:8–9, 2021. 5
- [9] X. Garcia, Y. Bansal, C. Cherry, G. Foster, M. Krikun, M. Johnson, and O. Firat. The unreasonable effectiveness of few-shot learning for machine translation. In ICML. PMLR. 1
- [10] R. M. Gray and D. L. Neuhoff. Quantization. IEEE transactions on information theory, 44(6):2325–2383, 1998. 1
- [11] S. Han, H. Mao, and W. J. Dally. Deep compression: Compressing deep neural networks with pruning, trained quantization and huffman coding. In ICLR, 2016. 1
- [12] G. Hinton, O. Vinyals, and J. Dean. Distilling the knowledge in a neural network. In NeurIPS Workshop, 2014. 1, 3
- [13] C. Hooper, S. Kim, H. Mohammadzadeh, M. W. Mahoney, Y. S. Shao, K. Keutzer, and A. Gholami. Kvquant: Towards 10 million context length llm inference with kv cache quantization. arXiv preprint arXiv:2401.18079, 2024. 2
- [14] B.-K. Kim, G. Kim, T.-H. Kim, T. Castells, S. Choi, J. Shin, and H.-K. Song. Shortened llama: A simple depth pruning for large language models. arXiv preprint arXiv:2402.02834, 11, 2024. 3
- [15] Y. LeCun, J. S. Denker, and S. A. Solla. Optimal brain damage. In NeurIPS, 1990. 3
- [16] Y. Li, L. Niu, X. Zhang, K. Liu, J. Zhu, and Z. Kang. E-sparse: Boosting the large language model inference through entropy-based n: M sparsity. arXiv preprint arXiv:2310.15929, 2023. 3
- [17] J. Lin, J. Tang, H. Tang, S. Yang, W.-M. Chen, W.-C. Wang, G. Xiao, X. Dang, C. Gan, and S. Han. Awq: Activation-aware weight quantization for on-device llm compression and acceleration. In MLSys, 2024. 1, 2
- [18] Z. Liu, B. Oguz, C. Zhao, E. Chang, P. Stock, Y. Mehdad, Y. Shi, R. Krishnamoorthi, and V. Chandra. Llm-qat: Data-free quantization aware training for large language models. arXiv preprint arXiv:2305.17888, 2023. 2
- [19] Z. Liu, J. Yuan, H. Jin, S. Zhong, Z. Xu, V. Braverman, B. Chen, and X. Hu. Kivi: A tuning-free asymmetric 2bit quantization for kv cache. arXiv preprint arXiv:2402.02750, 2024. 3
- [20] X. Ma, G. Fang, and X. Wang. Llm-pruner: On the structural pruning of large language models. In NeurIPS, 2023. 1, 3
- [21] M. Marcus, B. Santorini, and M. A. Marcinkiewicz. Building a large annotated corpus of english: The penn treebank. Computational linguistics, 19(2):313–330, 1993. 5
- [22] S. Merity, C. Xiong, J. Bradbury, and R. Socher. Pointer sentinel mixture models. arXiv preprint arXiv:1609.07843, 2016. 1, 5
- [23] T. Mihaylov, P. Clark, T. Khot, and A. Sabharwal. Can a suit of armor conduct electricity? a new dataset for open book question answering. arXiv preprint arXiv:1809.02789, 2018. 5
- [24] D. Paperno, G. Kruszewski, A. Lazaridou, Q. N. Pham, R. Bernardi, S. Pezzelle, M. Baroni, G. Boleda, and R. Fernández. The lambda dataset: Word prediction requiring a broad discourse context. arXiv preprint arXiv:1606.06031, 2016. 5
- [25] G. Park, B. Park, M. Kim, S. Lee, J. Kim, B. Kwon, S. J. Kwon, B. Kim, Y. Lee, and D. Lee. Lut-gemm: Quantized matrix multiplication based on luts for efficient inference in large-scale generative language models. arXiv preprint arXiv:2206.09557, 2022. 2
- [26] C. Raffel, N. Shazeer, A. Roberts, K. Lee, S. Narang, M. Matena, Y. Zhou, W. Li, and P. J. Liu. Exploring the limits of transfer learning with a unified text-to-text transformer. Journal of machine learning research, 21(140):1–67, 2020. 1, 5
- [27] R. Saha, V. Srivastava, and M. Pilanci. Matrix compression via randomized low rank and low precision factorization. In NeurIPS, 2023. 1, 4

- [28] P. Sharma, J. T. Ash, and D. Misra. The truth is in there: Improving reasoning in language models with layer-selective rank reduction. arXiv preprint arXiv:2312.13558, 2023. 4
- [29] N. Srebro and T. Jaakkola. Weighted low-rank approximations. In ICML, 2003. 4
- [30] A. Srivastava, A. Rastogi, A. Rao, A. A. M. Shob, A. Abid, A. Fisch, A. R. Brown, A. Santoro, A. Gupta, A. Garriga-Alonso, et al. Beyond the imitation game: Quantifying and extrapolating the capabilities of language models. arXiv preprint arXiv:2206.04615, 2022. 5
- [31] M. Sun, Z. Liu, A. Bair, and J. Z. Kolter. A simple and effective pruning approach for large language models. arXiv preprint arXiv:2306.11695, 2023. 3
- [32] A. Talmor, J. Herzig, N. Lourie, and J. Berant. Commonsenseqa: A question answering challenge targeting commonsense knowledge. arXiv preprint arXiv:1811.00937, 2018. 5
- [33] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin. Attention is all you need. In NeurIPS, 2017. 1
- [34] Y. Wang, Y. Kordi, S. Mishra, A. Liu, N. A. Smith, D. Khashabi, and H. Hajishirzi. Self-instruct: Aligning language models with self-generated instructions. arXiv preprint arXiv:2212.10560, 2022. 3, 5
- [35] J. Wei, X. Wang, D. Schuurmans, M. Bosma, F. Xia, E. Chi, Q. V. Le, D. Zhou, et al. Chain-of-thought prompting elicits reasoning in large language models. In NeurIPS, 2022. 3
- [36] H. Xia, Z. Zheng, Y. Li, D. Zhuang, Z. Zhou, X. Qiu, Y. Li, W. Lin, and S. L. Song. Flash-llm: Enabling cost-effective and highly-efficient large generative model inference with unstructured sparsity. arXiv preprint arXiv:2309.10285, 2023. 3
- [37] M. Xia, T. Gao, Z. Zeng, and D. Chen. Sheared llama: Accelerating language model pre-training via structured pruning. arXiv preprint arXiv:2310.06694, 2023. 3
- [38] G. Xiao, J. Lin, M. Seznec, H. Wu, J. Demouth, and S. Han. Smoothquant: Accurate and efficient post-training quantization for large language models. In ICML, 2023. 2
- [39] Z. Yao, R. Yazdani Aminabadi, M. Zhang, X. Wu, C. Li, and Y. He. Zeroquant: Efficient and affordable post-training quantization for large-scale transformers. In NeurIPS, 2022. 2
- [40] Z. Yuan, L. Niu, J. Liu, W. Liu, X. Wang, Y. Shang, G. Sun, Q. Wu, J. Wu, and B. Wu. Rptq: Reorder-based post-training quantization for large language models. arXiv preprint arXiv:2304.01089, 2023. 2
- [41] Z. Yuan, Y. Shang, Y. Song, Q. Wu, Y. Yan, and G. Sun. Asvd: Activation-aware singular value decomposition for compressing large language models. arXiv preprint arXiv:2312.05821, 2023. 4
- [42] Y. Yue, Z. Yuan, H. Duanmu, S. Zhou, J. Wu, and L. Nie. Wkvquant: Quantizing weight and key/value cache for large language models gains more. arXiv preprint arXiv:2402.12065, 2024. 3
- [43] Y. Zhang. Dialogpt: Large-scale generative pre-training for conversational response generation. arXiv preprint arXiv:1911.00536, 2019. 1
- [44] W. X. Zhao, K. Zhou, J. Li, T. Tang, X. Wang, Y. Hou, Y. Min, B. Zhang, J. Zhang, Z. Dong, et al. A survey of large language models. arXiv preprint arXiv:2303.18223, 2023. 1
- [45] L. Zheng, W.-L. Chiang, Y. Sheng, S. Zhuang, Z. Wu, Y. Zhuang, Z. Lin, Z. Li, D. Li, E. Xing, et al. Judging llm-as-a-judge with mt-bench and chatbot arena. In NeurIPS, 2023. 5
- [46] W. Zhu, H. Liu, Q. Dong, J. Xu, S. Huang, L. Kong, J. Chen, and L. Li. Multilingual machine translation with large language models: Empirical results and analysis. arXiv preprint arXiv:2304.04675, 2023. 1
- [47] X. Zhu, J. Li, Y. Liu, C. Ma, and W. Wang. A survey on model compression for large language models. arXiv preprint arXiv:2308.07633, 2023. 1, 3